

第四章：图像表达-边缘检测

授课老师：李厚强，胡洋，周文罡，李礼

图像表达内容提纲

□ 图像表达：特征检测与匹配

- 边缘检测，关键点检测，特征描述，视觉预训练模型

如何构建图像之间的关联关系？





边缘检测

- 边缘是图象中对象的基本的特征之一，可以通过检测物体边缘来提取所需物体

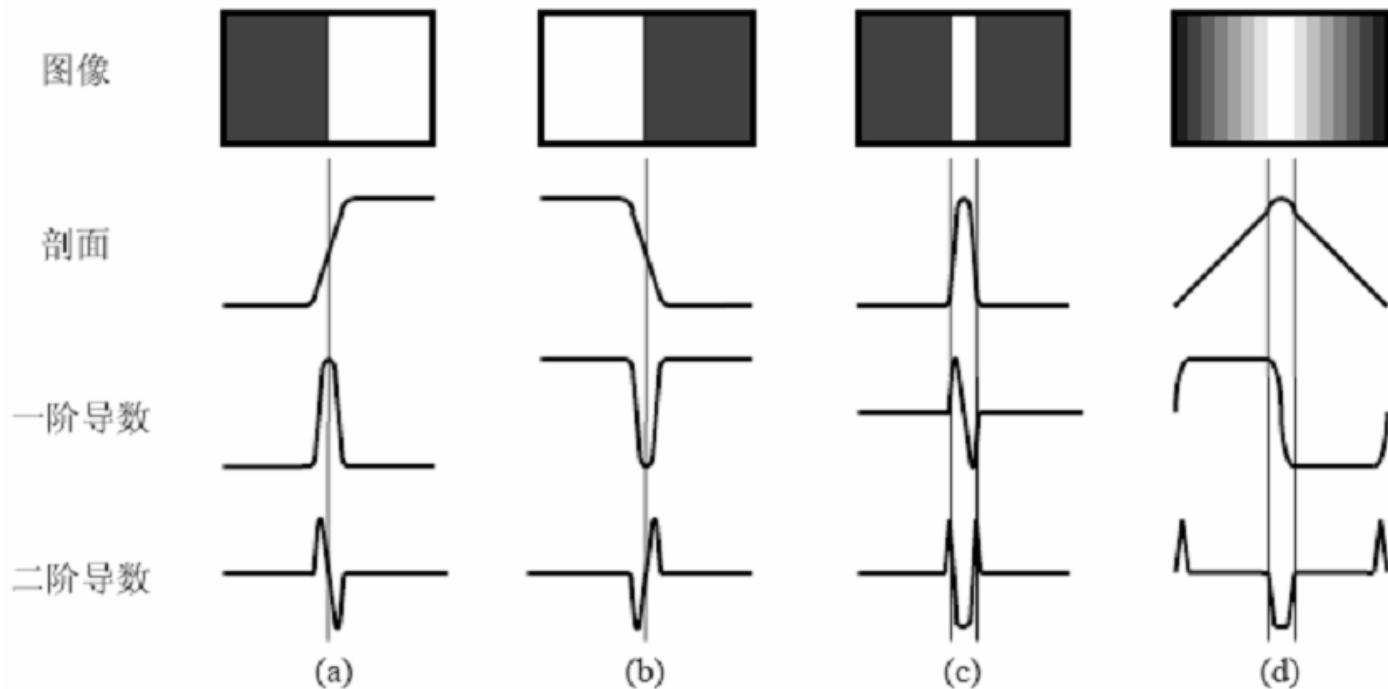
- **边缘模型**

- 边缘检测算子
 - 边缘拟合
 - 边缘搜索
 - 多尺度边缘检测

边缘模型

□ 边缘 (Edge)

- 一般出现在不同灰度、颜色、纹理区域的交界处

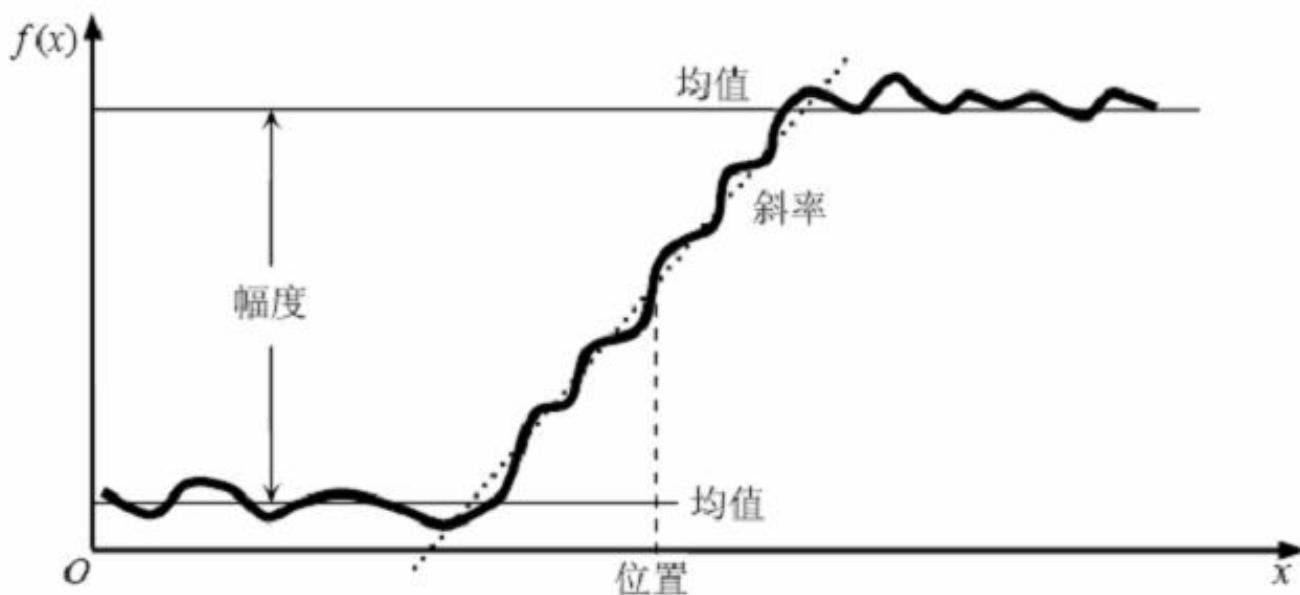


图象（灰度）边缘模型及其一阶、二阶导数

边缘模型

□ 描述边缘的参数

- 位置：边缘（等效的）最大灰度不连续处
- 朝向：跨越灰度最大不连续的方向
- 幅度：灰度不连续方向上的灰度差
- 均值：属于边缘的像素的灰度均值
- 斜率：边缘在其朝向上的倾斜程度





边缘检测

- 边缘是图象中对象的基本的特征之一，可以通过检测物体边缘来提取所需物体
 - 边缘模型
 - **边缘检测算子**
 - 边缘拟合
 - 边缘搜索
 - 多尺度边缘检测



边缘检测

□ 边缘检测算子

■ 正交梯度算子

✓ 梯度算子

■ 方向微分算子

✓ Kirsch 算子

■ 二阶导数算子

✓ 拉普拉斯 (Laplacian) 算子

✓ 马尔 (Marr) 算子

■ 最优边缘检测算子

✓ 坎尼 (Canny) 算子

■ SUSAN 算子

边缘检测 I：正交梯度算子

□ 梯度算子：一阶差分算子

梯度矢量: $\nabla f(x, y) = [G_x \quad G_y]^T = \left[\frac{\partial f}{\partial x} \quad \frac{\partial f}{\partial y} \right]^T$

梯度幅值: $\text{mag}(\nabla f) = \sqrt{G_x^2 + G_y^2}$

梯度方向角: $\varphi(x, y) = \arctan\left(\frac{G_y}{G_x}\right)$

中心差分: $\frac{\partial f}{\partial x} \approx 0.5 \cdot [f(x+1, y) - f(x-1, y)]$

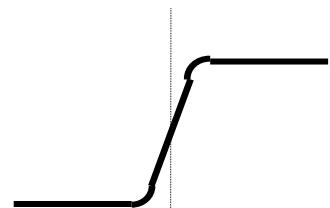
前向差分: $\frac{\partial f}{\partial x} \approx f(x+1, y) - f(x, y)$

后向差分: $\frac{\partial f}{\partial x} \approx f(x, y) - f(x-1, y)$

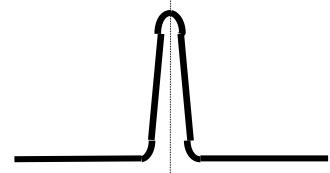
图象



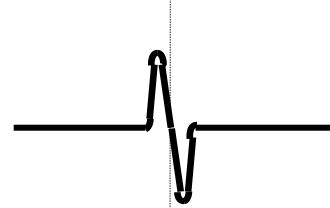
剖面



一阶导数



二阶导数





边缘检测 I：正交梯度算子

□ 梯度算子：一阶差分算子

- 由于差分运算会放大噪声影响，一般事先对图像做高斯平滑预处理
 - ✓ 等价于高斯函数梯度与图像做卷积

$$\mathbf{J}_\sigma(\mathbf{x}) = \nabla[G_\sigma(\mathbf{x}) * I(\mathbf{x})] = [\nabla G_\sigma](\mathbf{x}) * I(\mathbf{x})$$

- ✓ 高斯函数梯度

$$\nabla G_\sigma(\mathbf{x}) = \left(\frac{\partial G_\sigma}{\partial x}, \frac{\partial G_\sigma}{\partial y} \right)(\mathbf{x}) = [-x \ -y] \frac{1}{\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$

边缘检测 I：正交梯度算子

□ 梯度算子：利用模板（与图象进行）卷积

■ 模板比较

- ✓ ① 边缘粗细
- ✓ ② 方向性
- ✓ ③ 平滑操作：Prewitt 和 Sobel

1	
	-1

	1
-1	

(a) Roberts

-1		1
-1		1
-1		1

1	1	1
-1	-1	-1

(b) Prewitt

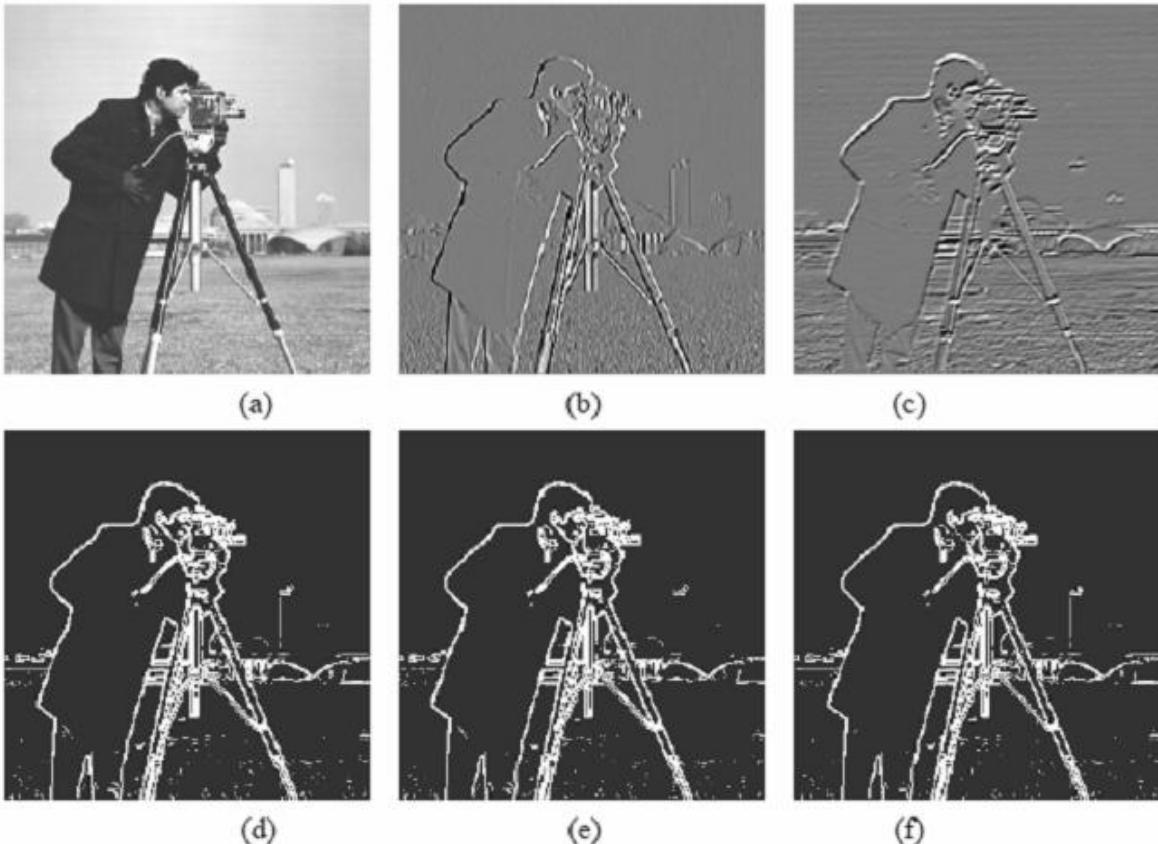
-1		1
-2		2
-1		1

(c) Sobel

1	2	1
-1	-2	-1

边缘检测 I：正交梯度算子

□ 梯度图示例



a) 原图； b) Sobel 水平模板； c) Sobel 垂直模板；
d) Sobel 梯度图（范数2） e) Sobel 梯度图（范数1） f) Sobel 梯度图（范数 ∞ ）

边缘检测 II：方向微分算子

- 基于特定方向上的微分来检测边缘

八方向Kirsch (7×7) 模板

-5	3	3
-5		3
-5	3	3

3	3	3
-5	0	3
-5	-5	3

3	3	3
3	0	3
-5	-5	-5

3	3	3
3	0	-5
3	-5	-5

3	3	-5
3		-5
3	3	-5

3	-5	-5
3	0	-5
3	3	3

-5	-5	-5
3	0	3
3	3	3

-5	-5	3
-5	0	3
3	3	3

边缘检测 II：方向微分算子

□ 用不同模板对图像进行卷积

1.0	1.0	1.0
-1.0	-1.0	-1.0

(a)

1.0	1.0	0.7
0.8		-0.8
-0.7	-1.0	-1.0

(b)

1.0	0.8	-0.7
1.0		-1.0
0.7	-0.8	-1.0

(c)

-1.0		1.0
-1.0		1.0
-1.0		1.0

(d)

-0.7	0.8	1.0
-1.0		1.0
-1.0	-0.8	0.7

(e)

0.7	1.0	1.0
-0.8		0.8
-1.0	-1.0	-0.7

(f)

- 边缘幅度：卷积值的最大值的绝对值
- 边缘方向：卷积值的最大值的符号
- 模板的对称性 → 模板数减半
- 可将各系数值线性变换到整数值，其中绝对值最小的系数变换为单位值



边缘检测 II：方向微分算子

- 有噪声时：边缘象素常孤立/分小段连续
- 封闭边界（轮廓）：连接边缘象素
- 一种具体方法
 - 利用象素梯度的幅度和方向：
 - ✓ 象素(s, t)在象素(x, y)的邻域

$$|\nabla f(x, y) - \nabla f(s, t)| \leq T$$

$$|\varphi(x, y) - \varphi(s, t)| \leq A$$



边缘检测 III：二阶导数算子

□ 1. 拉普拉斯算子：

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

□ 基于上面定义，离散化近似

- $\frac{\partial^2 f}{\partial x^2} \approx f_x(x + 0.5, y) - f_x(x - 0.5, y) = f(x + 1, y) - 2f(x, y) + f(x - 1, y)$
- $\frac{\partial^2 f}{\partial y^2} \approx f_y(x, y + 0.5) - f_y(x, y - 0.5) = f(x, y + 1) - 2f(x, y) + f(x, y - 1)$

□ 几种常用的拉普拉斯算子模板：

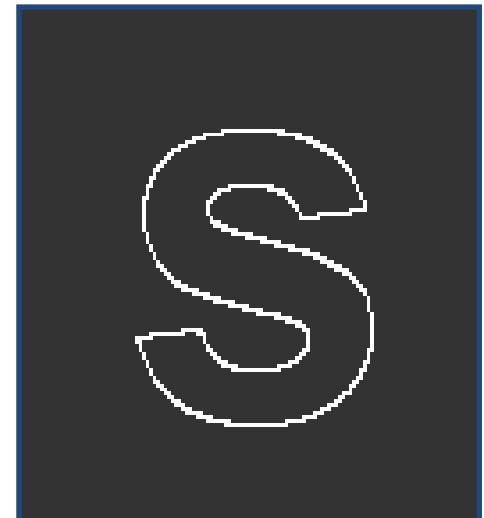
0	1	0
1	-4	1
0	1	0

1	1	1
1	-8	1
1	1	1

边缘检测 III：二阶导数算子

□ 1. 拉普拉斯算子

- 由于涉及二阶微分，对图象中的噪声相当敏感
- 产生双象素宽的边缘
- 滤波结果为标量，不能提供边缘方向的信息





边缘检测 III：二阶导数算子

□ 2. 马尔算子

- 在对函数算二阶微分前，先对图像进行高斯卷积（低通滤波）

$$\mathbf{J}_\sigma(\mathbf{x}) = \nabla[G_\sigma(\mathbf{x}) * I(\mathbf{x})] = [\nabla G_\sigma](\mathbf{x}) * I(\mathbf{x})$$

$$S_\sigma(\mathbf{x}) = \nabla \cdot \mathbf{J}_\sigma(\mathbf{x}) = [\nabla^2 G_\sigma](\mathbf{x}) * I(\mathbf{x})$$

$$\begin{aligned}\nabla^2 G_\sigma(\mathbf{x}) &= \left(\frac{x^2 + y^2}{\sigma^4} - \frac{2}{\sigma^2} \right) G_\sigma(\mathbf{x}) \\ &= \left(\frac{x^2}{2\sigma^4} - \frac{1}{\sigma^2} \right) G_\sigma(x) G_\sigma(y) + \left(\frac{y^2}{2\sigma^4} - \frac{1}{\sigma^2} \right) G_\sigma(y) G_\sigma(x)\end{aligned}$$

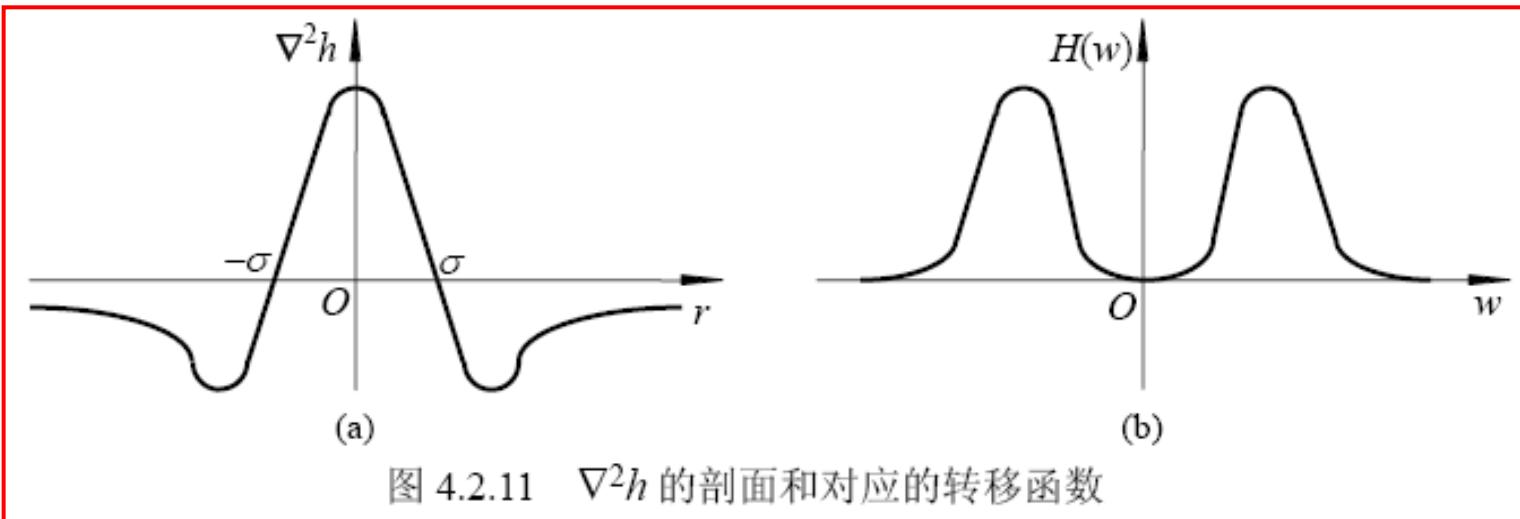
- 上述操作等价于：高斯函数的二阶导数与图像做卷积运算
 - ✓ 具体计算过程：
 - (1) 用一个2-D的高斯平滑模板与源图象卷积
 - (2) 计算卷积后图象的拉普拉斯值
 - (3) 检测拉普拉斯图象中的过零点作为边缘点

边缘检测 III：二阶导数算子

□ 2. 马尔算子

■ 等价于：高斯函数的二阶导数与图像做卷积运算

■ 马尔算子的一维函数及其频谱图：





边缘检测 IV：最优边缘检测算子

□ 好的边缘检测算子应具有的三个指标

- 低失误概率：既要少将真正的边缘丢失也要少将非边缘判为边缘

$$SNR = \frac{\left| \int_{-w}^{+w} G(-x)f(x) dx \right|}{n_0 \left[\int_{-w}^{+w} f^2(x) dx \right]^{\frac{1}{2}}}$$

- 高位置精度：检测出的边缘应在真正的边界上

$$Localization = \frac{\left| \int_{-w}^{+w} G'(-x)f'(x) dx \right|}{n_0 \sqrt{\int_{-w}^{+w} f'^2(x) dx}}$$

- 对每个边缘有唯一的响应：得到的边界为单象素宽

$$X_{zc}(f) = \pi \left(\frac{\int_{-\infty}^{\infty} f'^2(x) dx}{\int_{-\infty}^{\infty} f''^2(x) dx} \right)^{\frac{1}{2}}$$



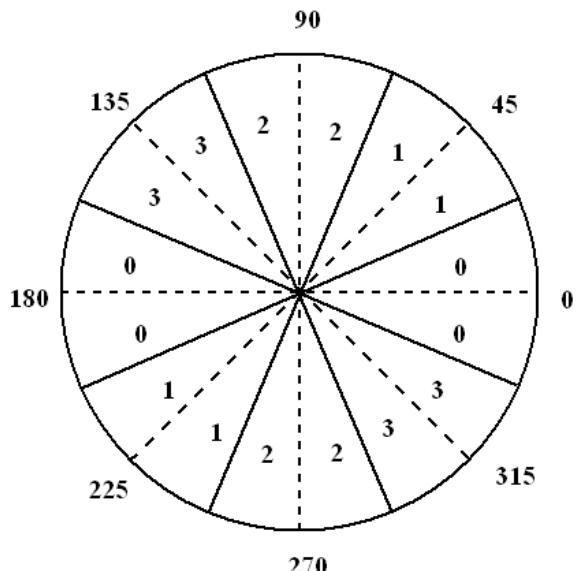
边缘检测 IV：最优边缘检测算子

□ Canny算子

- 可以用高斯函数的一阶微分算子来近似
- 算法基本步骤
 - ✓ 高斯滤波平滑
 - 对图像预处理，抑制噪声在计算梯度时的影响
 - ✓ 计算梯度幅度与方向
 - 计算一阶微分
 - ✓ 非极大值抑制
 - 实现边缘的高位置精度，得到的边界为单象素宽
 - ✓ 双阈值检测和连接
 - 避免真正的边缘丢失
 - 避免将非边缘判为边缘

Canny算子：非极大值抑制

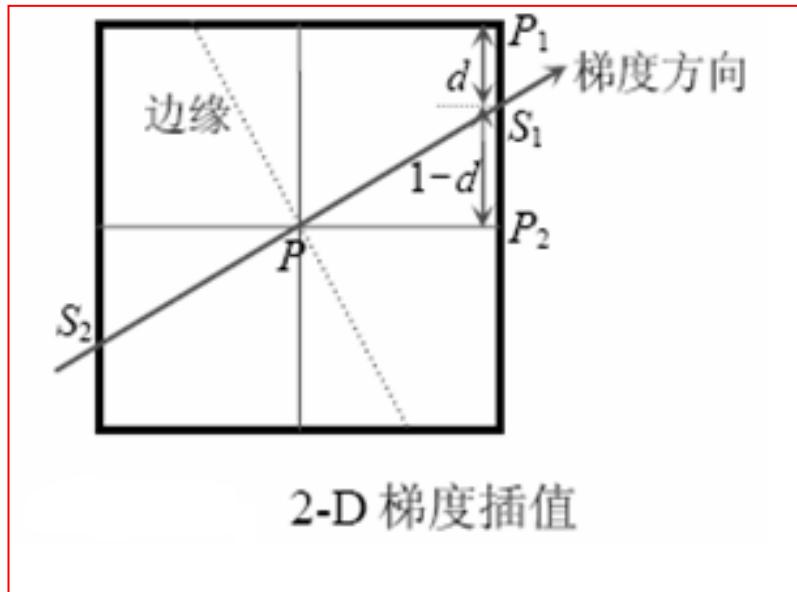
- 非极大值抑制 (non-maxima suppression, NMS)
 - 细化幅值图像 $M[i,j]$ 中的屋脊带(ridge)，只保留幅值局部变化最大的点
 - NMS通过抑制梯度线上所有非屋脊峰值的幅值来细化边缘。
 - 将梯度角 $\theta[i,j]$ 的变化范围分为四个扇区 $\zeta[i,j]=\text{Sector}(\theta[i,j])$;
 - 用 3×3 邻域作用于幅值图像 $M[i,j]$ ，邻域中心像素 $M[i,j]$ 与沿着梯度线方向的两个像素进行比较：若 $M[i,j]$ 不比沿梯度线方向的两个相邻点幅值大，则 $M[i,j]$ 置零。



Canny算子：非极大值抑制

□ 改进方法：用插值进行非最大消除

- 用插值进行最大值消除：精确但计算量大
- 思路：通过对相邻单元的梯度幅值的插值估计梯度线上的相邻幅值

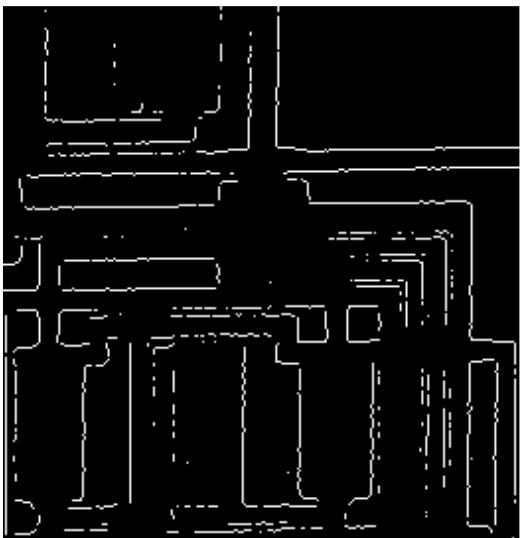
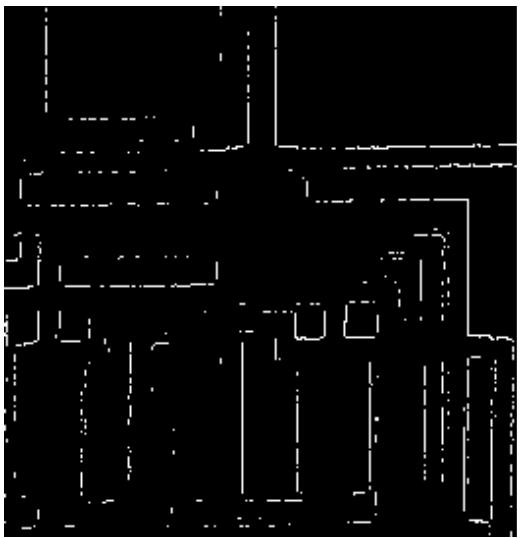
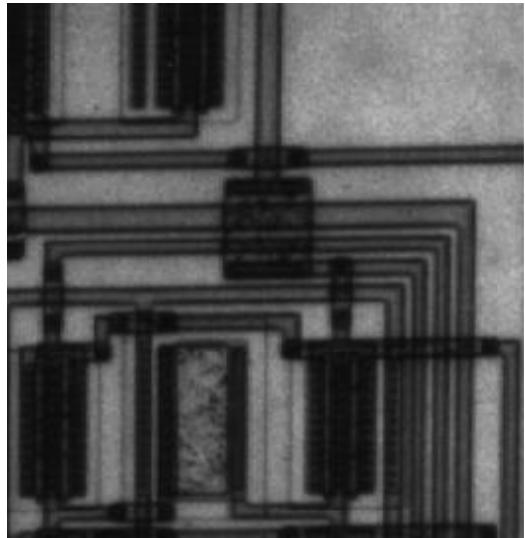




Canny算子：双阈值算法

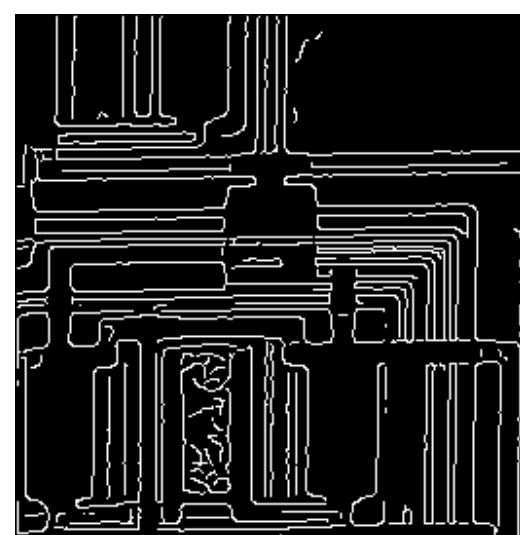
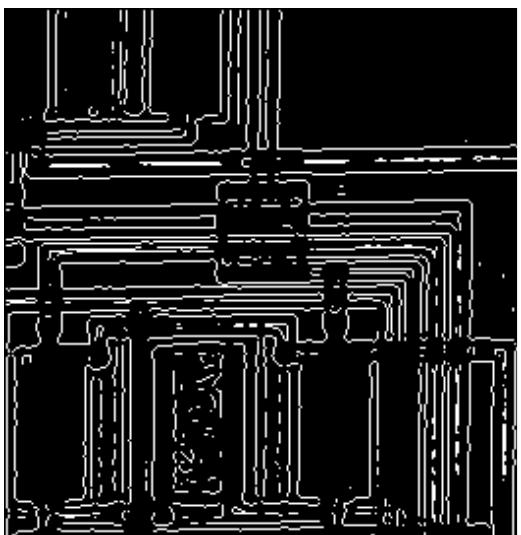
- 双阈值算法采用两个阈值 τ_1 和 τ_2 ，且 $\tau_2 \approx 2\tau_1$
- 得到两个阈值边缘图像 $T_1[i, j]$ 和 $T_2[i, j]$
 - 边缘图像 T_1 中的边缘点响应值 $\geq \tau_1$
 - 边缘图像 T_2 中的边缘点响应值 $\geq \tau_2$
- $T_2[i, j]$ 含有的假边缘少，但有间断点
- 以 $T_2[i, j]$ 为指导，在 $T_1[i, j]$ 中相应8邻域点寻找可以连接到轮廓上的点
- 不断在 $T_1[i, j]$ 收集边缘，直到将 $T_2[i, j]$ 中所有的间隙连接起来为止

边缘检测实例对比



Roberts Sobel

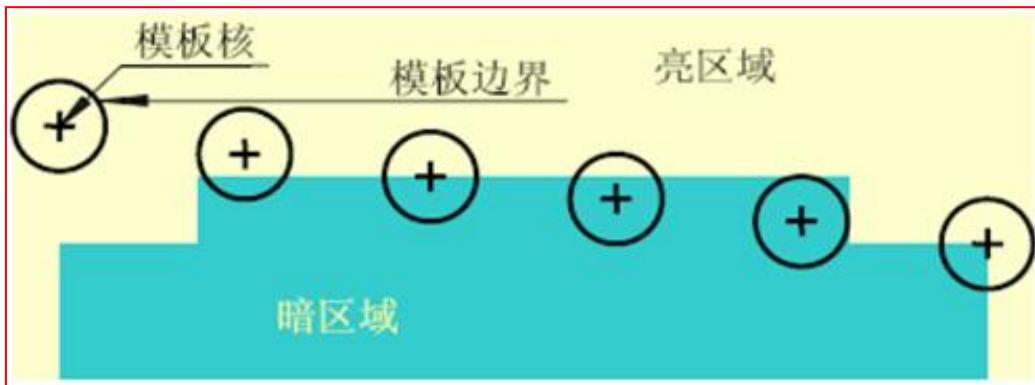
Log Canny



边缘检测 V: SUSAN算子

□ USAN: Univalue Segment Assimilating Nucleus

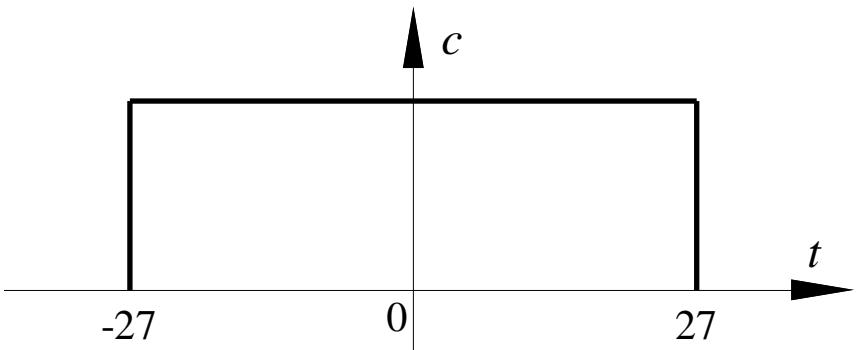
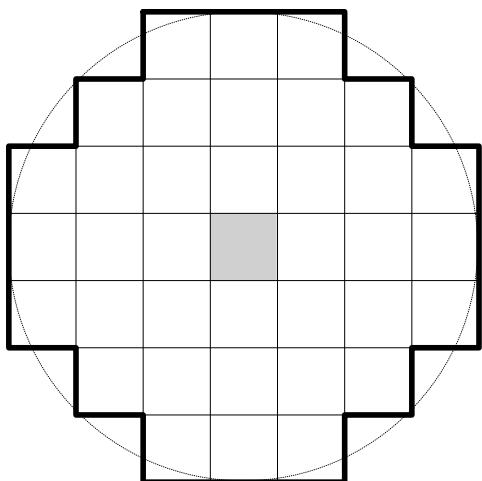
- 核同值区：相对于模板的核，模板中有一定的区域与它有相同灰度
- USAN面积携带了关于图象中核象素处结构的主要信息
 - ✓ 当核象素处在图象中的灰度一致区域，USAN的面积会达到最大。
 - ✓ 当核处在直边缘处该面积约最大值的一半，而当核处在角点处则为最大值的1/4
- 使用USAN面积作为特征起到了增强边缘和角点的效果



边缘检测 V: SUSAN算子

- SUSAN: 最小 (Smallest) 核同值区(USAN)
 - 检测模板: 37个象素, 半径为3.4象素

$$C(x_0, y_0; x, y) = \begin{cases} 1 & \text{如果 } |f(x_0, y_0) - f(x, y)| \leq T \\ 0 & \text{如果 } |f(x_0, y_0) - f(x, y)| > T \end{cases}$$





边缘检测 V: SUSAN算子

- 检测对模板中的每个象素进行
- 得到输出的游程和 (running total)

$$S(x_0, y_0) = \sum_{(x, y) \in N(x, y)} C(x_0, y_0; x, y)$$

- 边缘响应:

$$R(x_0, y_0) = \begin{cases} G - S(x_0, y_0) & \text{如果 } S(x_0, y_0) < G \\ 0 & \text{否则} \end{cases}$$

- 几何阈值 $G = 3S_{\max}/4$ (为了达到最佳信噪比)， 其中 S_{\max} 是 S 所能取的最大值，即模版面积。
- 物理意义：核同值区面积越小，边缘响应值越大

边缘检测 V: SUSAN算子

□ SUSAN算子特点

- 有噪声时的性能较好

- 不需要计算微分
- 对面积计算中的各个值求和（积分）
- 非线性响应特点

- 易自动化实现

- 控制参数的选择简单
- 参数的任意性较小

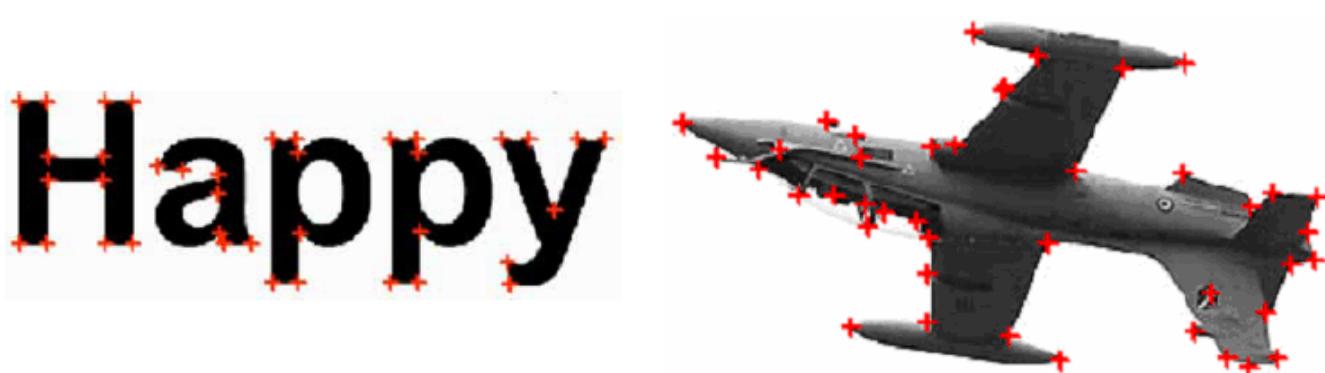
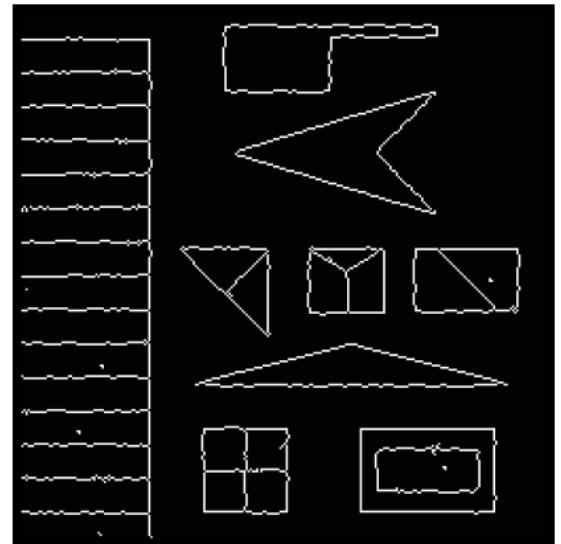
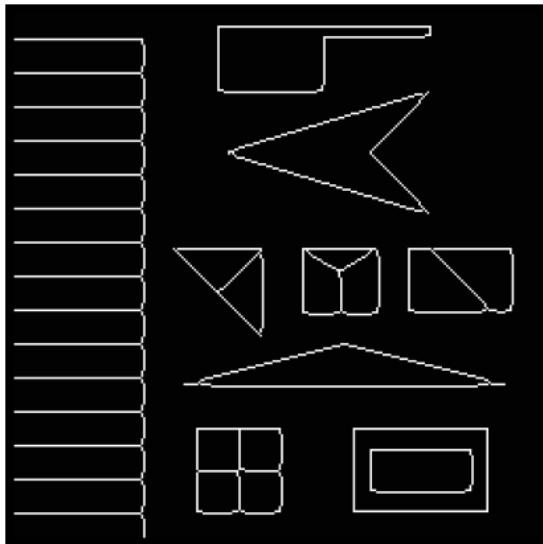
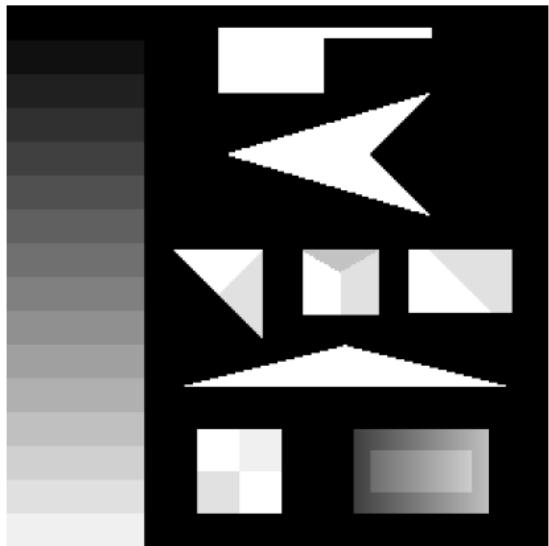


图 5.1.5 用 SUSAN 算子检测到的角点

边缘检测 V: SUSAN算子

□ SUSAN算子检测实例



左: 原图。 中: SUSAN检测结果。 右: 含高斯白噪声的结果。(SNR=0.5)

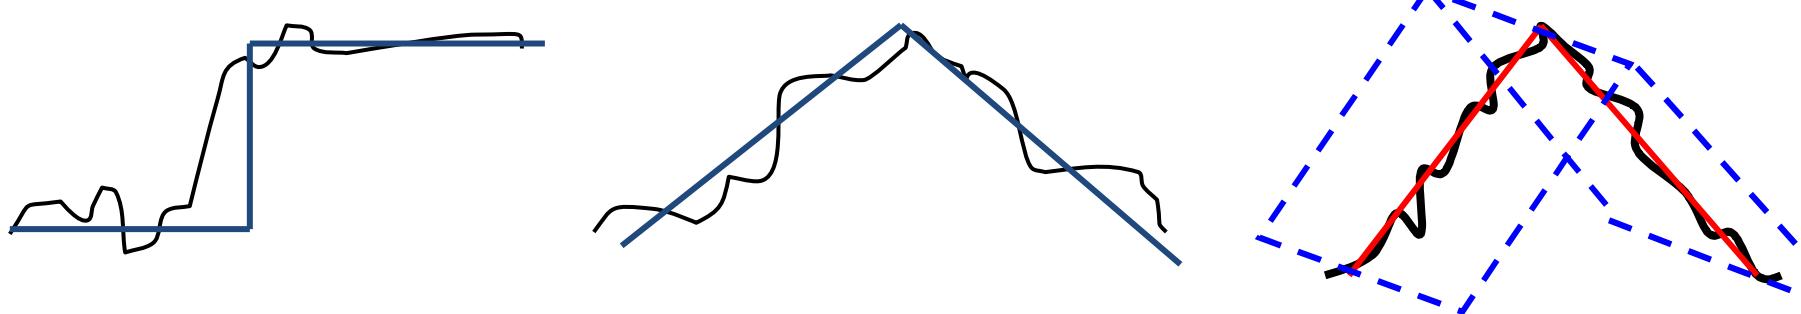


边缘检测

- 边缘是图象中对象的基本的特征之一，可以通过检测物体边缘来提取所需物体
 - 边缘模型
 - 边缘检测算子
 - 边缘拟合
 - 边缘搜索
 - 多尺度边缘检测

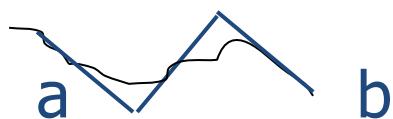
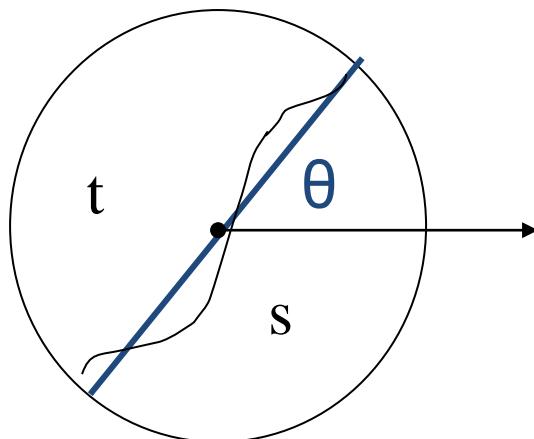
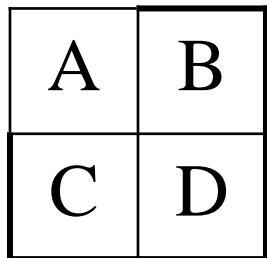
边缘拟合(Edge Fitting)

- 对图象中一个子区域，用理想灰度阶跃或斜变去拟合实际图象数据，从而求出拟合的理想模型参数，如阶跃幅度、斜变倾角等，并以此为这个子区域的边缘强度和方向度量
- 从某种意义上说，拟合本质是一种匹配滤波，旨在从失真和噪声中检测出理想边缘来。因此，有较强的抗噪声能力



灰度阶跃的拟合

- 构造原图象（或子图、小区域）的拟合曲面，再在拟合曲面上利用曲面的参数检测出边缘
 - 如：灰度阶跃边缘拟合。
 - ✓ 用理想灰度阶跃模型去拟合一个 2×2 的子图
 - ✓ 将子图 $f(x,y)$ 展开成基函数表达式。由均方误差最小求边缘幅度和角度





灰度阶跃的拟合

$$H(x, y) = \begin{cases} s & x \sin \theta > y \cos \theta \\ t & \text{其他} \end{cases}$$

A	B
C	D

在第一象限，有：

$$\theta = \frac{\pi}{4} \left(1 - \frac{B-C}{A-D}\right)$$

$$s = \frac{B}{4} - \frac{A-D}{2}$$

$$t = \frac{B}{4} + \frac{A-D}{2}$$

边缘幅度： $|s-t|=|A-D|$

当 θ 在第二象限：

边缘幅度： $|s-t|=|B-C|$

整副图象边缘幅度： $\max\{|A-D|, |B-C|\}$

与Roberts算子的结果相同



基于斜面模型的边缘检测

□ 拟合模型

- 将 $M \times N$ 的数字图象划分为相连接的区域集合 P , $P=(P_1, P_2, \dots, P_i, \dots)$
- P_i 的大小设为 $R \times C$ (通常为 3×3)

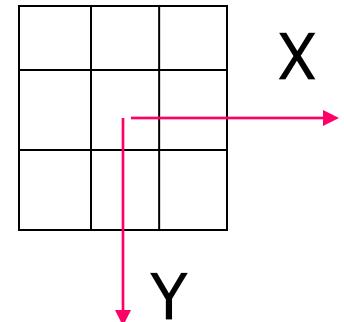
$$\hat{f}(x, y) = \alpha x + \beta y + \gamma$$

- 对每一个小区域 , 用一个斜平面来近似
- 拟合误差:

$$e^2 = \sum_R \sum_{\times C} [\alpha x + \beta y + \gamma - f(x, y)]^2$$

斜面拟合

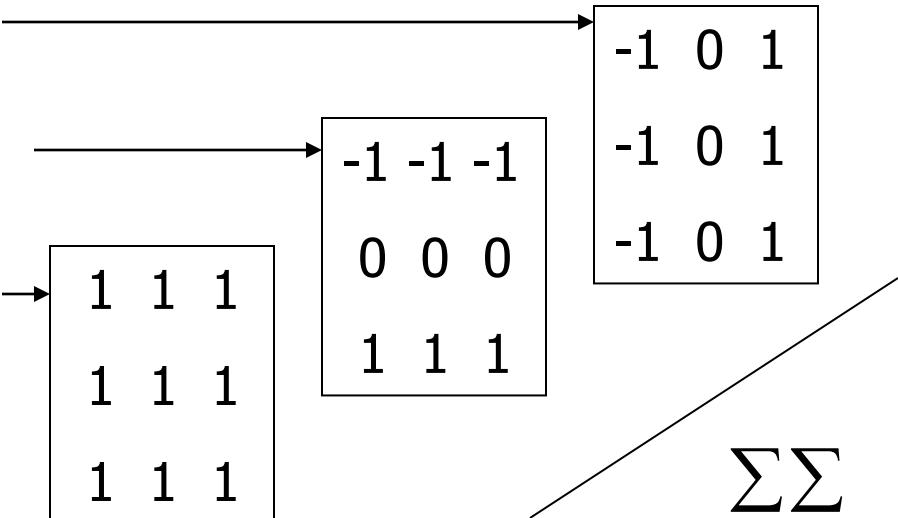
- 由均方误差最小来求 α 、 β 、 γ ,
- 区域 3×3 , 原点取在中心点时, 有:



$$\alpha = \sum_{R \times C} \sum x f(x, y) / \sum \sum x^2$$

$$\beta = \sum_{R \times C} \sum y f(x, y) / \sum \sum y^2$$

$$\gamma = \sum_{R \times C} \sum f(x, y) / \sum \sum 1$$



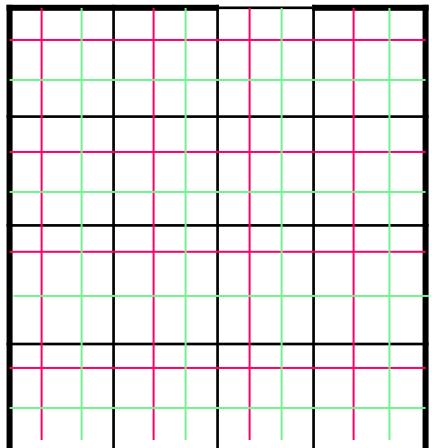
代入误差算式, 得出误差值。

误差较小时, 认为拟合可靠。

斜面交界的判断

- 对于“可靠”的斜面，把该拟合斜平面的参数作为小区域的参数（不重叠划分）或小区域中心点的参数（重叠划分）。
- 有：梯度值为： $\sqrt{\alpha^2 + \beta^2}$
方向为： $\theta = \tan^{-1} \frac{\alpha}{\beta}$
- 然后用斜面参数判断各个斜面间是否有边缘存在

即考察 $\alpha_1 = \alpha_2?$ $\beta_1 = \beta_2?$ $\gamma_1 = \gamma_2?$





基于斜面拟合的边缘检测

□ 一般步骤

- 选取适合的拟合区域
- 根据模型求解拟合系数
- 求拟合斜面各点灰度值
- 计算误差，判断斜面的可靠性
- 对于可靠的斜面，计算相邻点或区域不在同一斜面上的度量
- 选出边缘度量值局部最大的点，定为边缘点

边缘搜索：跟踪方法

□ 跟踪的一般步骤：

- 确定搜索的起点，对于边缘跟踪则起点是某一边缘点
- 采取一种合适的数据结构和搜索机理，在已有边缘点的基础上进行搜索，不断确定新的边缘点
- 规定搜索终止的条件，在满足条件时停止搜索

9				8			5
	5				6		4
		9			5		
6			4			7	
	7		6	2		9	
4		6			4		7
		5		2	6		
6	4				7		

$$T_d = 7$$

$$T_t = 4$$



边缘搜索：图搜索

□ 基本概念

- 边界点和边界段可以用图结构标示，通过在图中搜索达到某一目标的最佳路径（最短路径，最小消耗路径）寻找边缘。
- 路径评价函数可以定义为： $f(n)=g(n)+h(n)$
 - ✓ n : 搜索过程进行到的当前节点。
 - ✓ $g(n)$: 为从起始节点到当前节点所有路径代价。
 - ✓ $h(n)$: 是当前节点到目标节点将要经过的所有路径的代价。 (一般为对真实代价 $h(n)$ 的估计值，从而为启发项)

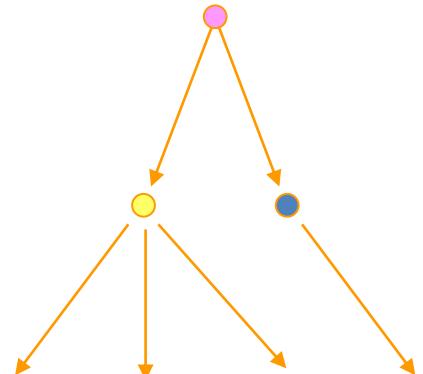
边缘搜索：图搜索

- 将边缘像素和边界段用图表示

图: $G = \{N, A\}$

结点集 $\{n_1, \dots\}$

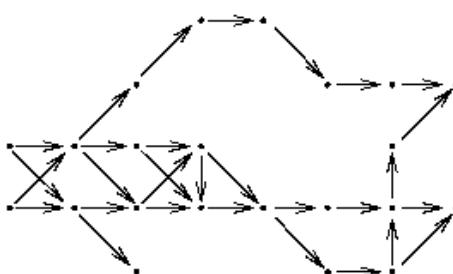
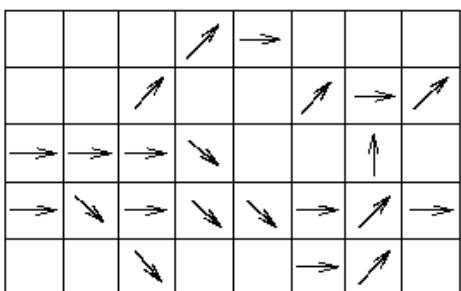
结点对集 $\{(n_i, n_j)\}$



- 通路代价: 通常跟灰度值的变化是相关的

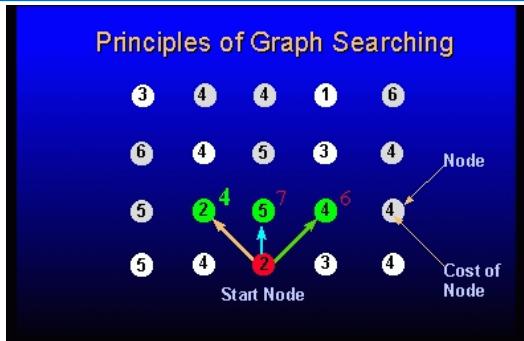
- 图的建立

$$C = \sum_{i=2}^K c(n_{i-1}, n_i)$$



(左) 显著边缘点的方向 (右) 相应的图

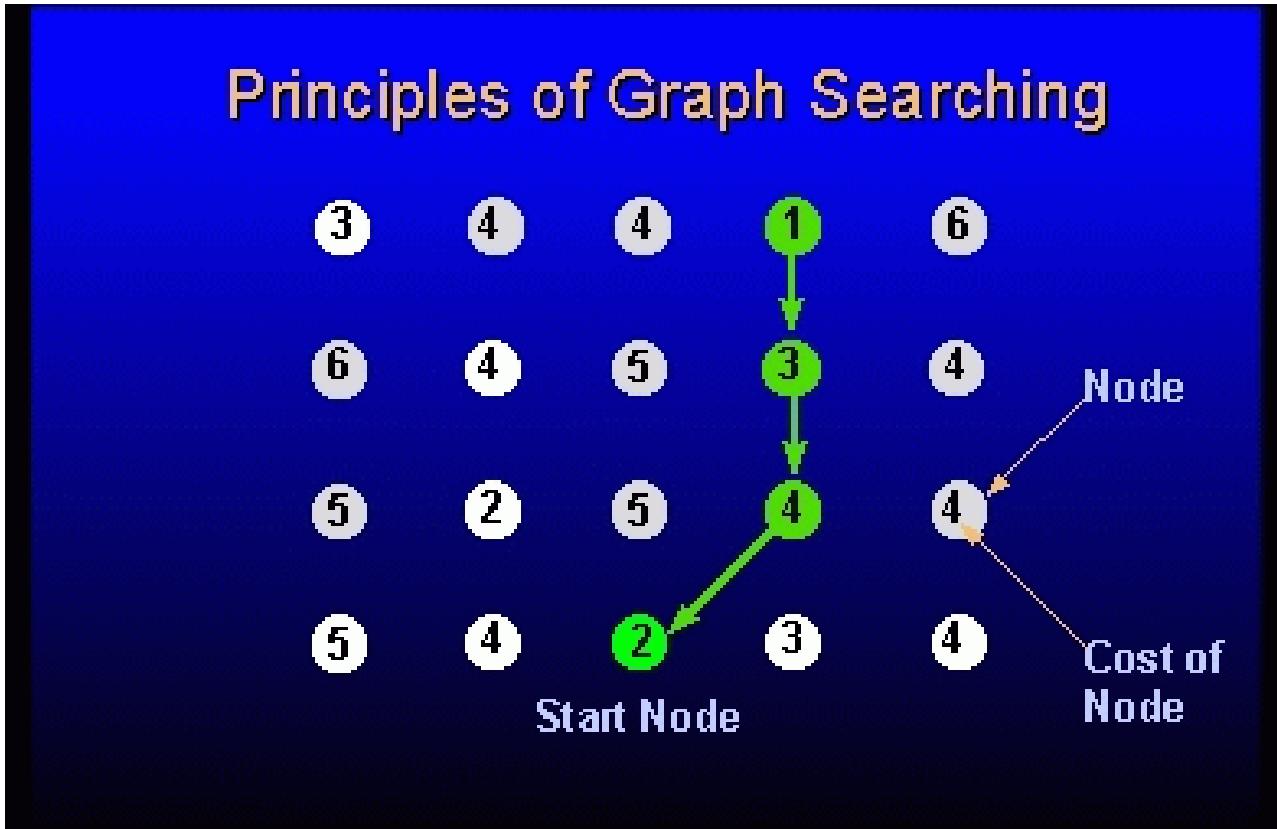
图搜索算法



Heuristic graph search

1. Expand the starting node n_A and put all its successors into an OPEN list with pointers back to the starting node n_A . Evaluate the cost function f for each expanded node.
2. If the OPEN list is empty, fail.
Determine the node n_i from the OPEN list with the lowest associated cost $f(n_i)$ and remove it. If $n_i = n_B$, then trace back through the pointers to find the optimum path and stop.
3. If the option to stop was not taken in step (2), expand the specified node n_i , and put its successors on the OPEN list with pointers back to n_i . Compute their costs f . Go to step (2).

图搜索实例



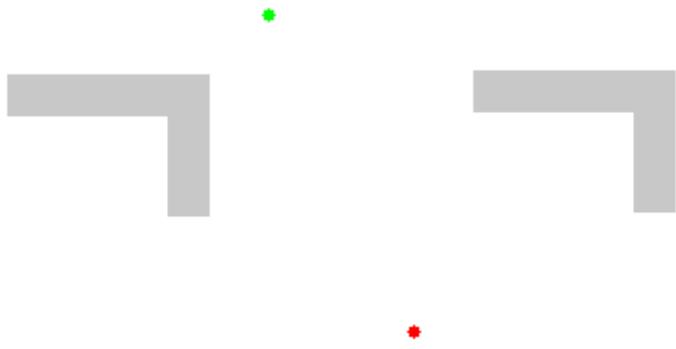
启发式图搜索

□ 利用问题拥有的启发信息来引导搜索，

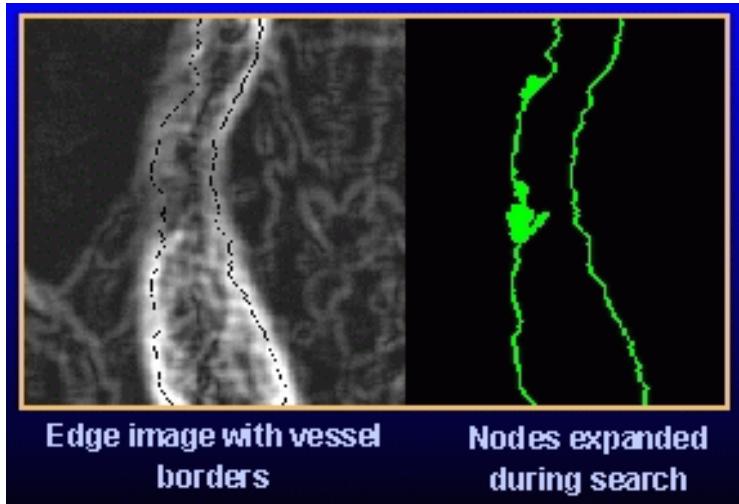
- 减少搜索范围
- 降低问题复杂度

□ 代价函数 $f(n)=g(n)+h(n)$

- 启发项 $h(n)$ 能加快搜索速度，但不一定能找到全局最优。
- 当无启发项 ($h(n)=0$) 时，一定能找到全局最优，但搜索范围加大。



普通搜索过程演示 启发式搜索过程演示





代价函数的设计

- 使用“启发”信息，构造评价函数，计算路径的耗费，是启发式搜索的关键。
- 具体如何构造则要分析该问题的具体情况，将多种因素合理的分离开来，把实际情况中的约束转化为计算机可操作的表达式。
 - 灰度梯度的幅度
 - 灰度梯度的方向
 - 路径的曲率
 - 路径与某一函数的近似程度
 - 到目标点的距离等
 -



4.5 多尺度边缘检测

□ 现象

- 大尺度下能较可靠地消除误检，检测到真正边缘点，但定位不准；
- 小尺度定位较准，但误检增加；
- 大尺度检测真正边缘点，小尺度精确定位
- 图像不同的边缘信息会在不同的尺度下表现

□ 方法

- 融合各个尺度的检测结果，获得稳定的边缘信息。

基于二进小波的多尺度边缘检测

用于边缘检测的二进小波：

母函数： $\varphi(x, y) = \exp(-(x^2 + y^2)/\sigma^2)/2\pi\sigma^2$ ；(高斯核函数)

小波函数： $\psi^1 = \frac{\partial \varphi}{\partial x}$; $\psi^2 = \frac{\partial \varphi}{\partial y}$;

二进小波变换： $S_{2^j} f \rightarrow \{W_{2^j}^1 f, W_{2^j}^2 f, S_{2^{j+1}} f\}$ (离散算法 α -trous)

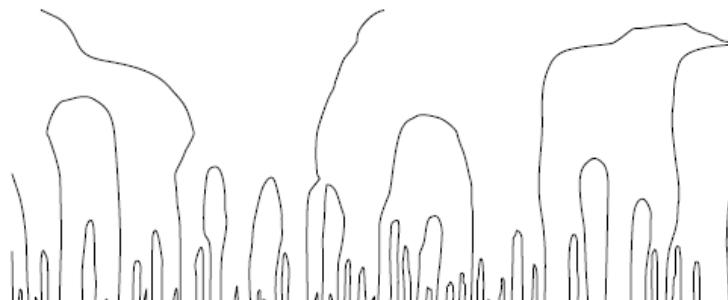
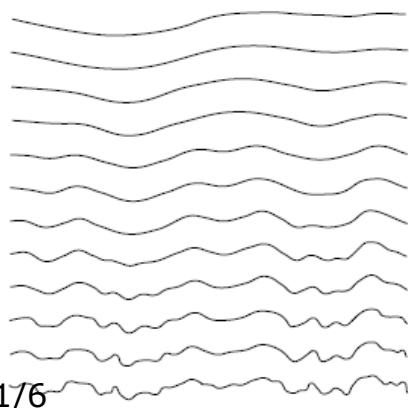
$W_{2^j}^i f = \langle f, \psi_{2^j}^i \rangle$; $i = 1, 2$; (分别对应水平和竖直边缘)

$S_{2^{j+1}} f = \langle f, \varphi_{2^j} \rangle$; (平滑信号)

模值 $M_{2^j} f = \sqrt{|W_{2^j}^1 f|^2 + |W_{2^j}^2 f|^2}$; 幅角 $A_{2^j} f = \arctan(W_{2^j}^1 f / W_{2^j}^2 f)$;

模极大链：

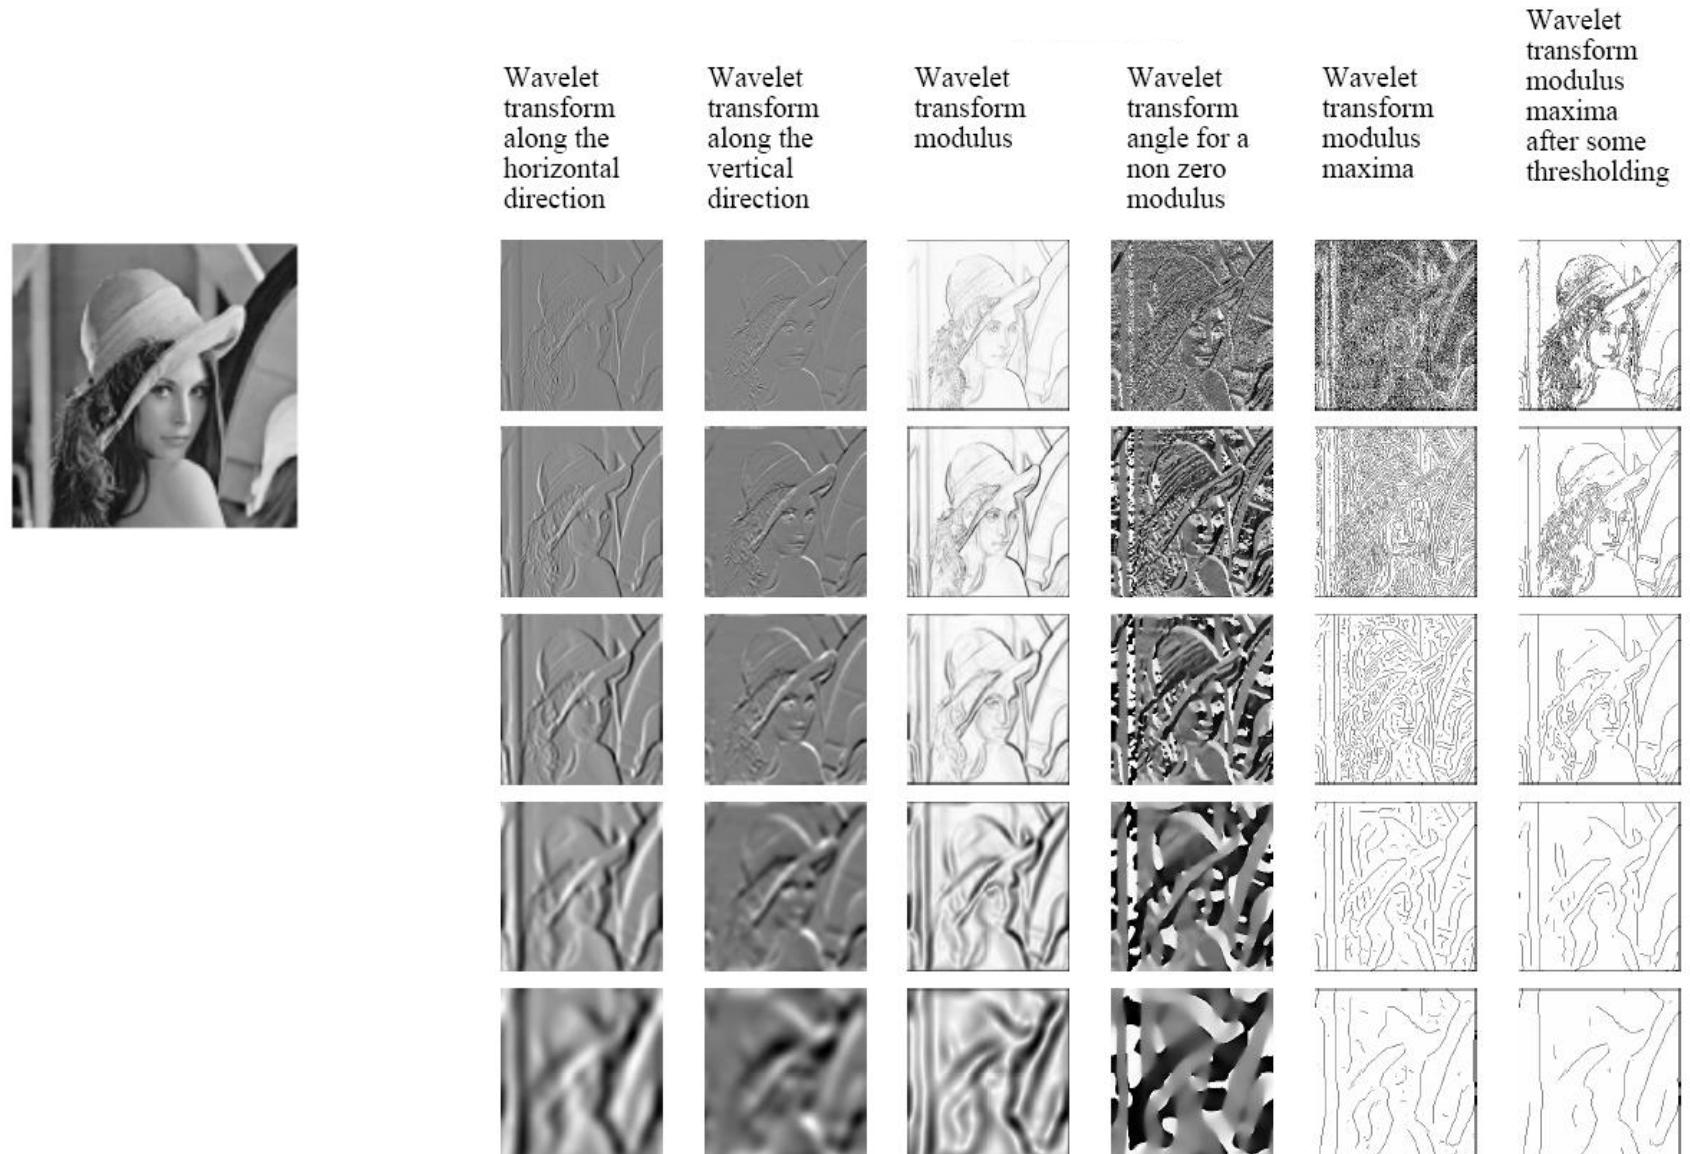
小波系数的模极大值(即导数的过零点), 在尺度空间会形成“向下开口”的连续曲线。



左：不同尺度
的平滑信号

右：尺度空间
的模极大链

基于二进小波的多尺度边缘检测





基于二进小波的多尺度边缘检测

□ 算法步骤：

- 1.选择二进小波 $\{\psi^1, \psi^2\}$, 分解级数J, 和模阈值T;
- 2.对图像 f 进行二进小波变换, 得到 $S_{2^J} f$ 和 $\{W_{2^j}^1 f, W_{2^j}^2 f\}_{j=1}^J$;
- 3.计算模值 $M_{2^j} f = \sqrt{|W_{2^j}^1 f|^2 + |W_{2^j}^2 f|^2}$;
- 4.计算幅角 $A_{2^j} f = \arctan(W_{2^j}^1 f / W_{2^j}^2 f)$;
- 5.用非极大值抑制得到小波系数的局部模极大值点;
- 6.把局部模极大值点延尺度连起来, 得到极值链;
- 7.利用模阈值T和极值链长度阈值, 去除由噪声引起或不感兴趣的的边界;