



第十一章：运动分析

中国科学技术大学
电子工程与信息科学系

主讲教师：李厚强 (lihq@ustc.edu.cn)
周文罡 (zhwg@ustc.edu.cn)
李 礼 (li11@ustc.edu.cn)
胡 洋 (eeychu@ustc.edu.cn)



运动分析


- **二维运动模型**
- 二维运动 vs. 光流
- 运动估计中的一般方法
- 基于块的运动估计
- 可形变块匹配
- 多分辨率运动估计
- 相位相关法
- 基于深度学习的运动分析



二维运动模型


- 相机投影
- 三维运动
- 三维运动的投影
- 刚体目标的二维运动
 - 投影映射
- 投影映射的近似
 - 仿射模型
 - 双线性模型

针孔相机模型



The image of an object is reversed from its 3-D position. The object appears smaller when it is farther away.

针孔相机模型：透视投影



$$\frac{x}{F} = \frac{X}{Z}, \frac{y}{F} = \frac{Y}{Z} \Rightarrow x = F \frac{X}{Z}, y = F \frac{Y}{Z}$$

x, y are inversely related to Z



三维运动——刚体运动模型

刚体运动模型： $X' = R \cdot X + T$

$X' = X + T$ 平移

旋转 $[R] = [R_z] \cdot [R_y] \cdot [R_x]$


$$[R_x] = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \theta_x & -\sin \theta_x \\ 0 & \sin \theta_x & \cos \theta_x \end{bmatrix}$$

$$[R_y] = \begin{bmatrix} \cos \theta_y & 0 & \sin \theta_y \\ 0 & 1 & 0 \\ -\sin \theta_y & 0 & \cos \theta_y \end{bmatrix}$$

$$[R_z] = \begin{bmatrix} \cos \theta_z & -\sin \theta_z & 0 \\ \sin \theta_z & \cos \theta_z & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$[R] \approx [R'] = \begin{bmatrix} 1 & -\theta_z & \theta_y \\ \theta_z & 1 & -\theta_x \\ -\theta_y & \theta_x & 1 \end{bmatrix}$$


三维运动——刚体运动模型



Rotation and translation wrt. the object center :

$$\mathbf{X}' = [\mathbf{R}] (\mathbf{X} - \mathbf{C}) + \mathbf{T} + \mathbf{C}; \quad [\mathbf{R}] : \theta_x, \theta_y, \theta_z; \quad \mathbf{T} : T_x, T_y, T_z$$

三维与二维运动之间的关系



MV: motion vector



定义和符号

□ 三维运动向量

$$D(X; t_1, t_2) = X' - X = [D_X, D_Y, D_Z]^T$$

□ 二维运动向量

$$d(X; t_1, t_2) = X' - X = [d_x, d_y]^T$$

□ 映射函数


$$w(X; t_1, t_2) = X'$$

$$w(X) = X + d(X)$$

□ 流矢量（速度矢量）


$$V = \frac{\partial d}{\partial t} = \left[\frac{\partial d_x}{\partial t}, \frac{\partial d_y}{\partial t} \right]^T$$

一个典型的二维运动场





遮挡的影响

□ 在遮挡区域，运动是未定义的



典型的相机运动

□ 接下来介绍典型的相机运动对应的2D运动





相机平移：跟(track)与吊(boom)

$$\begin{bmatrix} X' \\ Y' \\ Z' \end{bmatrix} = \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} + \begin{bmatrix} T_x \\ T_y \\ 0 \end{bmatrix} \Leftrightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} FT_x / Z \\ FT_y / Z \end{bmatrix}$$

当 $\Delta Z \ll \bar{Z}$

$$\begin{bmatrix} d_x(x, y) \\ d_y(x, y) \end{bmatrix} = \begin{bmatrix} t_x \\ t_y \end{bmatrix}, t_x = \frac{FT_x}{\bar{Z}}, t_y = \frac{FT_y}{\bar{Z}}$$



相机摇(Pan)与倾(Tilt)

$$\begin{bmatrix} X' \\ Y' \\ Z' \end{bmatrix} = [R_x][R_y] \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} \quad [R_x][R_y] = \begin{bmatrix} 1 & 0 & \theta_y \\ 0 & 1 & -\theta_x \\ -\theta_y & \theta_x & 1 \end{bmatrix}$$

如果 $Y\theta_x \ll Z, X\theta_y \ll Z$, 那么 $Z' \approx Z$

$$\begin{bmatrix} d_x(x, y) \\ d_y(x, y) \end{bmatrix} = \begin{bmatrix} \theta_y F \\ -\theta_x F \end{bmatrix}$$

相机推(Zoom)和滚(Roll)

□ 推 (zoom) : 像平面与中心点距离 (焦距) 被改变


$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} \rho x \\ \rho y \end{bmatrix} \Rightarrow \begin{bmatrix} d_x(x, y) \\ d_y(x, y) \end{bmatrix} = \begin{bmatrix} (1 - \rho)x \\ (1 - \rho)y \end{bmatrix} \quad (\rho = F' / F)$$

□ 滚 (roll)

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} \cos \theta_z & -\sin \theta_z \\ \sin \theta_z & \cos \theta_z \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} \approx \begin{bmatrix} 1 & -\theta_z \\ \theta_z & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$


$$\begin{bmatrix} d_x(x, y) \\ d_y(x, y) \end{bmatrix} = \begin{bmatrix} -\theta_z y \\ \theta_z x \end{bmatrix}$$

相机运动的运动场



(a)

Camera zoom



(b)

Camera rotation around **Z**-axis (roll)

四参数模型

- 考虑一个顺序地进行平移、摇、倾、变焦和旋转的摄像机
- 几何映射：

$$\begin{aligned} \begin{bmatrix} x' \\ y' \end{bmatrix} &= \rho \begin{bmatrix} \cos \theta_z & -\sin \theta_z \\ \sin \theta_z & \cos \theta_z \end{bmatrix} \begin{bmatrix} x + \theta_y F + t_x \\ y - \theta_x F + t_y \end{bmatrix} \\ &= \begin{bmatrix} c_1 & -c_2 \\ c_2 & c_1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} c_3 \\ c_4 \end{bmatrix} \end{aligned}$$

- 这个映射函数有四个参数，是仿射映射的一个特例，仿射映射一般有6个参数。



相应于三维刚性运动的二维运动模型

- 之前的相机运动模型均没有考虑相机在Z方向的平移运动
- 一般情况：

$$\begin{bmatrix} X' \\ Y' \\ Z' \end{bmatrix} = \begin{bmatrix} r_1 & r_2 & r_3 \\ r_4 & r_5 & r_6 \\ r_7 & r_8 & r_9 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} + \begin{bmatrix} T_x \\ T_y \\ T_z \end{bmatrix}$$

—————→
Perspective Projection

$$x' = F \frac{(r_1 x + r_2 y + r_3 F)Z + T_x F}{(r_7 x + r_8 y + r_9 F)Z + T_z F}$$
$$y' = F \frac{(r_4 x + r_5 y + r_6 F)Z + T_y F}{(r_7 x + r_8 y + r_9 F)Z + T_z F}$$



投影映射

□ 投影映射

- 在Z方向没有平移运动
- 目标有平坦表面

$$x' = \frac{a_0 + a_1x + a_2y}{1 + c_1x + c_2y}, \quad y' = \frac{b_0 + b_1x + b_2y}{1 + c_1x + c_2y}$$

□ 实际图像可以分成多个包含平坦平面的区域



仿射和双线性模型

□ 仿射 (6个参数):

- 适合将一个三角形映射到一个三角形

$$\begin{bmatrix} d_x(x, y) \\ d_y(x, y) \end{bmatrix} = \begin{bmatrix} a_0 + a_1x + a_2y \\ b_0 + b_1x + b_2y \end{bmatrix}$$


□ 双线性 (8个参数):

- 适合将一个四边形映射为一个曲边四边形

$$\begin{bmatrix} d_x(x, y) \\ d_y(x, y) \end{bmatrix} = \begin{bmatrix} a_0 + a_1x + a_2y + a_3xy \\ b_0 + b_1x + b_2y + b_3xy \end{bmatrix}$$


不同二维运动模型的运动场

平移




(a)

仿射




(b)

双线性



(c)

透视



(d)




运动分析

- 二维运动模型
- **二维运动 vs. 光流**
- 运动估计中的一般方法
- 基于块的运动估计
- 可形变块匹配
- 多分辨率运动估计
- 相位相关法
- 基于深度学习的运动分析

二维运动 vs. 光流

- 观察到的二维运动并不一定和实际的二维运动相同
- 仅知道图像颜色信息的情况下最好的方式就是估计光流
- 光流：基于图片模式的变化“感知”二维运动，也依赖于光照和目标表面纹理



左边：球体在恒定环境照明下转动，但是观测的图像没有变化。

右边：点绕着静止的球转动，引起球上的亮点旋转。



光流方程

- 在光照条件未知的情况下，最优的估计方法是光流估计
- 恒定亮度假设 → 光流方程

Under "constant intensity assumption":

$$\psi(x + d_x, y + d_y, t + d_t) = \psi(x, y, t)$$

But, using Taylor's expansion:

$$\psi(x + d_x, y + d_y, t + d_t) = \psi(x, y, t) + \frac{\partial \psi}{\partial x} d_x + \frac{\partial \psi}{\partial y} d_y + \frac{\partial \psi}{\partial t} d_t$$

Compare the above two, we have the optical flow equation:

$$\frac{\partial \psi}{\partial x} d_x + \frac{\partial \psi}{\partial y} d_y + \frac{\partial \psi}{\partial t} d_t = 0 \quad \text{or} \quad \frac{\partial \psi}{\partial x} v_x + \frac{\partial \psi}{\partial y} v_y + \frac{\partial \psi}{\partial t} = 0 \quad \text{or} \quad \nabla \psi^T \mathbf{v} + \frac{\partial \psi}{\partial t} = 0$$




如何使用光流方程

$$f_t \approx \frac{1}{4} [f(x, y, t+1) + f(x+1, y, t+1) + f(x, y+1, t+1) + f(x+1, y+1, t+1)] \\ - \frac{1}{4} [f(x, y, t) + f(x+1, y, t) + f(x, y+1, t) + f(x+1, y+1, t)]$$

$$f_x \approx \frac{1}{4} [f(x+1, y, t) + f(x+1, y+1, t) + f(x+1, y, t+1) + f(x+1, y+1, t+1)] \\ - \frac{1}{4} [f(x, y, t) + f(x, y+1, t) + f(x, y, t+1) + f(x, y+1, t+1)]$$

运动估计的二义性

- 光流方程仅包含梯度 v_n 方向的流向量
- 切线方向 v_t 的流向量是未定义的
- 在恒定亮度区域 $\nabla \psi = 0$ ，光流是不确定的
 - 在平坦纹理区域，运动估计是不可靠的，更可靠的是靠近边缘的区域





$$\nabla \psi^T \mathbf{v} + \frac{\partial \psi}{\partial t} = 0$$

$$\mathbf{v} = v_n \mathbf{e}_n + v_t \mathbf{e}_t$$

$$v_n \|\nabla \psi\| + \frac{\partial \psi}{\partial t} = 0$$

孔径问题 (Aperture problem)

<http://elvers.us/perception/aperture/>





运动分析

- 二维运动模型
- 二维运动 vs. 光流
- **运动估计中的一般方法**
- 基于块的运动估计
- 可形变块匹配
- 多分辨率运动估计
- 相位相关法
- 基于深度学习的运动分析




运动估计的一般考虑


- 三个重要问题
 - 如何表达运动场？
 - 用什么标准来估计运动参数？
 - 如何搜索运动参数？

运动表达

整体：
整个运动场被一些全局
参数表达。




(a)




(b)

基于像素：
每一个像素有一个运动
向量，在相邻运动向量
之间有一些平滑约束。

基于块：
整个帧被分为若干个块，
每个块中的运动由一些
参数描述。



(c)

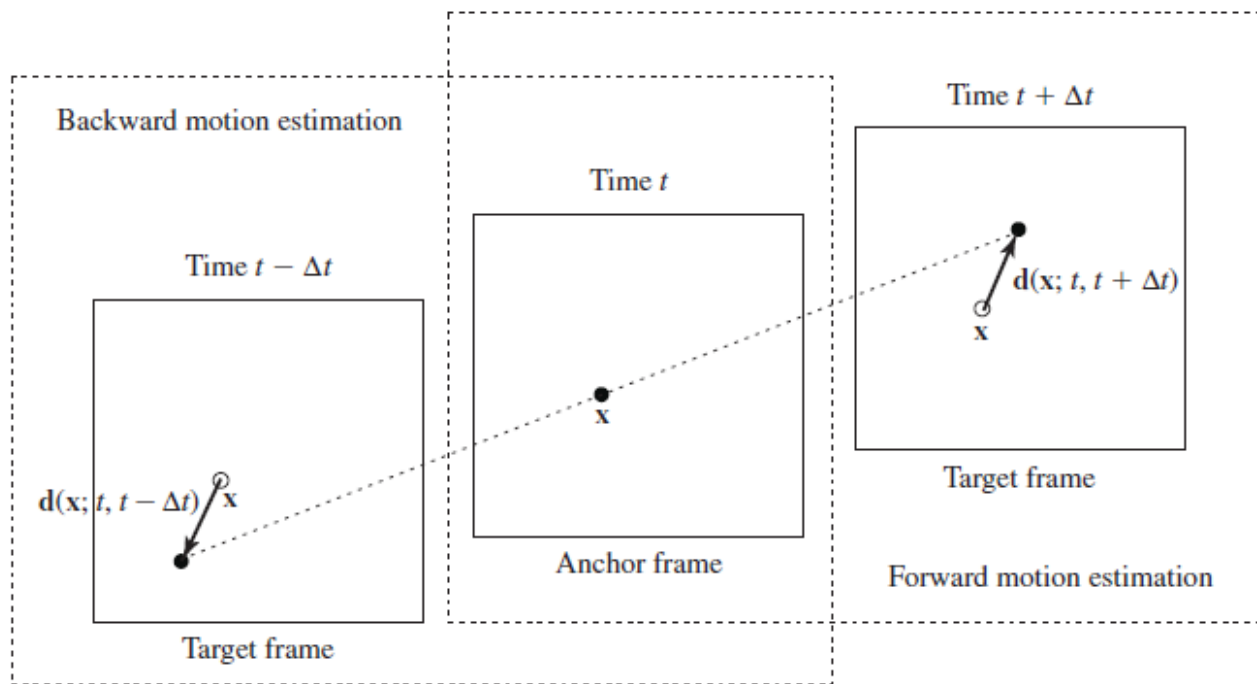


(d)

基于区域：
整帧被划分为若干区域，
每个区域对应一个具有
一致运动的目标或者子
目标，并用一些参数表
达。

其他表达：基于网格（控制网格）

运动估计准则符号定义



锚帧: $\psi_1(\mathbf{x})$

目标帧: $\psi_2(\mathbf{x})$

运动参数: \mathbf{a}

锚帧中一个像素点的
运动向量: $\mathbf{d}(\mathbf{x})$

运动场: $\mathbf{d}(\mathbf{x}; \mathbf{a}), \mathbf{x} \in \Lambda$

映射函数:

$\mathbf{w}(\mathbf{x}; \mathbf{a}) = \mathbf{x} + \mathbf{d}(\mathbf{x}; \mathbf{a}), \mathbf{x} \in \Lambda$



运动估计准则 (1)

□ 基于位移帧差准则 (DFD criterion)

$$E_{\text{DFD}}(\mathbf{a}) = \sum_{\mathbf{x} \in \Lambda} |\psi_2(\mathbf{x} + \mathbf{d}(\mathbf{x}; \mathbf{a})) - \psi_1(\mathbf{x})|^p \rightarrow \min$$

$$p=1: \text{MAD}; \quad P=2: \text{MSE}$$

$$\frac{\partial E_{\text{DFD}}}{\partial \mathbf{a}} = 2 \sum_{\mathbf{x} \in \Lambda} (\psi_2(\mathbf{w}(\mathbf{x}; \mathbf{a})) - \psi_1(\mathbf{x})) \frac{\partial \mathbf{d}(\mathbf{x})}{\partial \mathbf{a}} \nabla \psi_2(\mathbf{w}(\mathbf{x}; \mathbf{a}))$$

□ 基于光流方程准则 (OF criterion)

$$\frac{\partial \psi_1}{\partial x} d_x + \frac{\partial \psi_1}{\partial y} d_y + (\psi_2 - \psi_1) = 0 \quad \text{or} \quad \nabla \psi_1^T \mathbf{d} + (\psi_2 - \psi_1) = 0$$

$$E_{\text{flow}}(\mathbf{a}) = \sum_{\mathbf{x} \in \Lambda} \left| (\nabla \psi_1(\mathbf{x}))^T \mathbf{d}(\mathbf{x}; \mathbf{a}) + \psi_2(\mathbf{x}) - \psi_1(\mathbf{x}) \right|^p \rightarrow \min$$

$$\frac{\partial E_{\text{flow}}}{\partial \mathbf{a}} = 2 \sum_{\mathbf{x} \in \Lambda} (\nabla \psi_1(\mathbf{x})^T \mathbf{d}(\mathbf{x}; \mathbf{a}) + \psi_2(\mathbf{x}) - \psi_1(\mathbf{x})) \frac{\partial \mathbf{d}(\mathbf{x})}{\partial \mathbf{a}} \nabla \psi_1(\mathbf{x})$$

运动估计准则 (2)

- 正则化准则：利用额外的平滑项 (smoothness) 约束 (important in pixel- and block-based representation)

$$E_s(\mathbf{a}) = \sum_{\mathbf{x} \in \Lambda} \sum_{\mathbf{y} \in N_x} \|\mathbf{d}(\mathbf{x}; \mathbf{a}) - \mathbf{d}(\mathbf{y}; \mathbf{a})\|^2$$

$$w_{DFD} E_{DFD}(\mathbf{a}) + w_s E_s(\mathbf{a}) \rightarrow \min$$

- 贝叶斯准则 (Bayesian criterion)：最大化后验概率

$$P(D = \mathbf{d} | \psi_2, \psi_1) \rightarrow \max$$

$$P(\mathcal{D} = \mathbf{d} | \Psi = \psi_2; \psi_1) = \frac{P(\Psi = \psi_2 | \mathcal{D} = \mathbf{d}; \psi_1) P(\mathcal{D} = \mathbf{d}; \psi_1)}{P(\Psi = \psi_2; \psi_1)}$$

$$\mathbf{d}_{\text{MAP}} = \operatorname{argmax}_{\mathbf{d}} \{P(\Psi = \psi_2 | \mathcal{D} = \mathbf{d}; \psi_1) P(\mathcal{D} = \mathbf{d}; \psi_1)\}$$

$$\begin{aligned} \mathbf{d}_{\text{MAP}} &= \operatorname{argmax}_{\mathbf{d}} \{P(\mathcal{E} = e) P(\mathcal{D} = \mathbf{d}; \psi_1)\} \\ &= \operatorname{argmin}_{\mathbf{d}} \{-\log P(\mathcal{E} = e) - \log P(\mathcal{D} = \mathbf{d}; \psi_1)\} \end{aligned}$$



不同准则之间的联系

- OF误差准则 (OF criterion) 只有当运动较小的情况下表现良好
- 在OF误差准则下，当目标函数是MV的二次函数时，那么该函数具有封闭式解
- 当运动较大时，最好应用DFD误差准则
- 基于Bayesian准则 (Bayesian criterion) 的运动估计可以被简化为具有适当平滑约束的基于DFD的估计



优化方法

□ 穷举搜索

- 通常在DFD准则 ($p=1$) 下被采用
- 保证达到全局最优解
- 当同时搜索的参数数目很大时, 所需计算量可能是不可接受的
- 改进的快速搜索算法可以达到次优解并减少搜索时间

□ 基于梯度搜索

- 通常在DFD准则 ($p=2$) 和OF准则 ($p=2$) 下被采用
 - ✓ 梯度往往可以被解析计算得到
 - ✓ 在OF准则下, 通常可以得到闭式解
- 容易得到一个接近于初始解的局部最优解, 需要通过先验知识获得一个良好的初始解

□ 多分辨率搜索策略

- 由粗到精地搜索, 比穷举搜索迅速
- 避免陷入局部最优解



运动分析

- ☐ 二维运动模型
- ☐ 二维运动 vs. 光流
- ☐ 运动估计中的一般方法
- ☐ **基于块的运动估计**
- ☐ 可形变块匹配
- ☐ 多分辨率运动估计
- ☐ 相位相关法
- ☐ 基于深度学习的运动分析



块匹配算法

- 假设一个块内所有像素都具有一致的运动，即可独立地估计每个块的运动参数
- 块匹配算法 (BMA): 仅**平移运动**, 对每个块估计一个MV (1 MV, 2 parameter)
 - 穷举BMA (EBMA)
 - 快速算法



块匹配算法 (BMA)

□ 概述:

- 假设块中所有像素仅有同一个平移运动, 用一个MV即可表示
- 通过最小化块中的DFD误差, 估计MV


□ 目标函数:

$$E_{\text{DFD}}(\mathbf{d}_m) = \sum_{\mathbf{x} \in B_m} |\psi_2(\mathbf{x} + \mathbf{d}_m) - \psi_1(\mathbf{x})|^p \rightarrow \min$$

□ 优化方法:

- 穷举搜索
 - ✓ 每次只需要求解一个MV
 - ✓ 可使用MAD准则, 即 $p=1$
- 快速搜索算法
- 整数精度搜索 vs. 分数精度搜索

穷举BMA (EBMA)





整数像素精度EBMA复杂度


- 假设
 - 图像尺寸: $M \times M$
 - 块尺寸: $N \times N$
 - 搜索范围: $(-R, R)$ in each dimension
 - 搜索步长: 1 pixel (assuming integer MV)
- 操作数 (Operation counts):
(1 operation=1 “-”, 1 “abs”, 1 “+”)
 - 每个候选位置的像素灰度比较数: N^2
 - 每个参考块需要遍历的候选位置: $(2R + 1)^2$
 - 整一帧: $(M/N)^2 (2R + 1)^2 N^2 = M^2 (2R + 1)^2$
 - ✓ 独立于块尺寸!
- 例子: $M=512, N=16, R=16, 30 \text{ fps}$
 - 总操作数 = $2.85 \times 10^8 / \text{frame} \times 30 \text{ frame/s} = 8.55 \times 10^9 / \text{s}$
- 适用于超大规模集成电路 (VLSI) 进行实现
 - 软件实现困难




分数像素精度EBMA

- MV估计中，搜索步长并不一定是一个整数，在实际情况下，分数步长可能更合适
- 半像素精度EBMA: step-size=1/2 pixel in both dimension
- 困难：
 - 目标帧仅有整数像素点
- 解决方案：
 - 在搜索之前目标帧先进行2倍内插
- 计算复杂度：
 - 4倍于整数像素精度，并加上额外的插值开销
- 快速算法：
 - 首先以整数精度进行搜索，然后在小范围内以半像素精度进行细化

半像素精度EBMA



双线性插值



$$O[2x,2y]=I[x,y]$$

$$O[2x+1,2y]=(I[x,y]+I[x+1,y])/2$$

$$O[2x,2y+1]=(I[x,y]+I[x+1,y])/2$$

$$O[2x+1,2y+1]=(I[x,y]+I[x+1,y]+I[x,y+1]+I[x+1,y+1])/4$$


target frame



anchor frame



Motion field



Predicted anchor frame (29.86dB)



Example: 半像素精度EBMA



BMA快速算法

□ 如何减少EBMA计算量？

■ 降低搜索候选块的数量：

- ✓ 只搜索那些可能产生小误差的块
- ✓ 根据之前的搜索结果，预测可能剩下的候选块

■ 简化误差度量准则 (DFD)

□ 经典的快速算法


■ 三步搜索法 (Three-step)

■ 二维对数搜索法 (2D-log)

□ 还有许多新的快速算法

■ 有些适合软件实现，有些适合VLSI实现

三步搜索法



R_0 : initial search step

Search step L

$$L = \lfloor \log_2 R_0 + 1 \rfloor$$


Total number: $8L+1$

For example

$R=32$

EBMA: $4225 = (2R+1)^2$

3Step: $41 = 8*5+1$





EBMA存在的问题(I)

□ 块效应 (块边界的不连续性)

- 基于块的平移运动模型不准确，实际的运动情况比平移更复杂
 - ✓ 解决方案: 可形变BMA (deformable BMA)
- 在一个块中可能有多个具有不同运动的对象
 - ✓ 解决方案:
 - 基于区域的运动估计
 - 基于网格模型的运动估计
- 光照影响
 - ✓ 进行光照补偿以满足“恒定光强假设”



EBMA存在的问题 (II)

□ 运动场混乱

- 原因：逐块**独立**地估计MV
- 解决方案：
 - ✓ 加入显式的**平滑约束项**
 - ✓ 多分辨率方法
 - ✓ 基于网格模型的运动估计

□ 平坦区的MV预测出错

- 当空间上梯度接近于零时，运动难以确定
- 应该使用非规则的理想的分块
- 解决方案：基于区域的运动估计

□ 需要巨大的计算量

- 解决方案：
 - ✓ 快速算法：多分辨率方法




运动分析

- ☐ 二维运动模型
- ☐ 二维运动 vs. 光流
- ☐ 运动估计中的一般方法
- ☐ 基于块的运动估计
- ☐ **可形变块匹配**
- ☐ 多分辨率运动估计
- ☐ 相位相关法
- ☐ 基于深度学习的运动分析

可形变块匹配

- 之前的图像块匹配算法主要考虑平移运动，无法刻画旋转、缩放、仿射等更高阶的运动
- 可形变块匹配算法
 - 面向更高阶运动的图像块匹配算法




可形变块匹配

□ 基于顶点的运动信息表征

- 基于参数的运动模型不适合与现有编码框架
- 使用顶点的运动信息表示

$$\mathbf{d}_m(\mathbf{x}) = \sum_{k=1}^K \phi_{m,k}(\mathbf{x}) \mathbf{d}_{m,k}, \quad \mathbf{x} \in \mathcal{B}_m.$$



可形变块匹配

□ 运动估计方法

$$E(\mathbf{a}) = \sum_{\mathbf{x} \in \mathcal{B}} |\psi_2(\mathbf{w}(\mathbf{x}; \mathbf{a})) - \psi_1(\mathbf{x})|^p$$

$$\mathbf{w}(\mathbf{x}; \mathbf{a}) = \mathbf{x} + \sum_{k \in \mathcal{K}} \phi_k(\mathbf{x}) \mathbf{d}_k$$

□ 基于梯度的方法

$$\frac{\partial E}{\partial \mathbf{a}}(\mathbf{a}) = \left[\frac{\partial E}{\partial \mathbf{a}_x}(\mathbf{a}), \frac{\partial E}{\partial \mathbf{a}_y}(\mathbf{a}) \right]^T$$

$$\frac{\partial E}{\partial \mathbf{a}_x}(\mathbf{a}) = 2 \sum_{x \in \mathcal{B}} e(\mathbf{x}; \mathbf{a}) \frac{\partial \psi_2(\mathbf{w}(\mathbf{x}; \mathbf{a}))}{\partial x} \phi(\mathbf{x}),$$

$$\frac{\partial E}{\partial \mathbf{a}_y}(\mathbf{a}) = 2 \sum_{x \in \mathcal{B}} e(\mathbf{x}; \mathbf{a}) \frac{\partial \psi_2(\mathbf{w}(\mathbf{x}; \mathbf{a}))}{\partial y} \phi(\mathbf{x}).$$



运动分析

- ☐ 二维运动模型
- ☐ 二维运动 vs. 光流
- ☐ 运动估计中的一般方法
- ☐ 基于块的运动估计
- ☐ 可形变块匹配
- ☐ **多分辨率运动估计**
- ☐ 相位相关法
- ☐ 基于深度学习的运动分析



多分辨率运动估计


□ BMA存在缺陷

- 除非使用穷举搜索，否则可能难以达到全局最优解
- 穷举搜索需要非常大的计算量
- 基于块的平移运动模型并不总是合适的


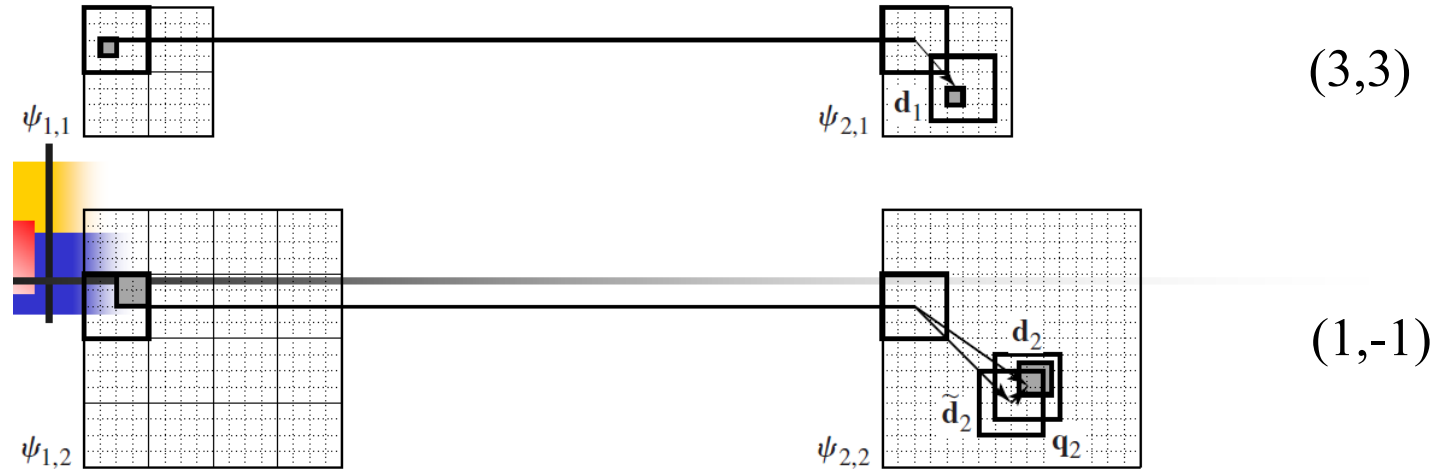
□ 多分辨率估计方法

- 解决上述前两个问题
- 首先在低通滤波、下采样的图像对上，进行低分辨率下的运动估计
 - ✓ 通常能得到一个接近于真实运动场的解
- 然后在较小的搜索范围内以更高的分辨率逐步改善初始解
 - ✓ 降低计算量
- 可以应用于不同的运动场景下，后续内容中我们只集中介绍其在BMA中的应用

多分辨率运动估计



分层块匹配算法 (HBMA)





分层块匹配算法 (HBMA)

Number of levels: L

t th level image: $\Psi_{t,l}(X), X \in \Lambda_l, t = 1, 2$

Interpolation operator: $\tilde{d}_l(X) = \mathcal{U}(d_{l-1}(X))$

Error function: $\sum_{X \in \Lambda_l} |\Psi_{2,l}(X + \tilde{d}_l(X) + q_l(X)) - \Psi_{1,l}(X)|^p$

Update motion vector: $d_l(X) = \tilde{d}_l(X) + q_l(X)$


MV at l th level prediction:

$$\tilde{d}_{l,m,n}(X) = \mathcal{U}(d_{l-1, \lfloor m/2 \rfloor, \lfloor n/2 \rfloor}(X)) = 2d_{l-1, \lfloor m/2 \rfloor, \lfloor n/2 \rfloor}(X)$$

Total motion:

$$d_l(X) = q_L(X) + \mathcal{U}(q_{L-1}(X) + \mathcal{U}(q_{L-2}(X) \cdots + \mathcal{U}(q_1(X) + d_0(X)) \cdots))$$


分层块匹配算法 (HBMA)



(a)




(b)



(c)



(d)



(e)



(f)

Predicted anchor frame (29.32dB)

Example: Three-level HBMA



HBMA复杂度

□ 假设

- 图像尺寸: $M \times M$
- 块尺寸: $N \times N$ at every level; Levels: L
- 搜索范围:
 - ✓ 1st level: $R/2^{(L-1)}$ (Equivalent to R in L -th level)
 - ✓ Other levels: $R/2^{(L-l)}$ (can be smaller)

□ EBMA

- 图像尺寸 = $M \times M$, 块尺寸 = $N \times N$, 搜索范围 = $(-R, R)$
- 操作数: $M^2(2R+1)^2$

□ HBMA l -th level 操作数 (图像尺寸: $M/2^{L-l}$)

$$\left(M / 2^{L-l}\right)^2 \left(2R / 2^{L-l} + 1\right)^2$$

□ HBMA总操作数

$$\sum_{l=1}^L \left(M / 2^{L-l}\right)^2 \left(2R / 2^{L-l} + 1\right)^2 \approx \frac{1}{3} 4^{-(L-2)} 4M^2 R^2$$


□ EBMA / HBMA: $3 \cdot 4^{(L-2)} = 3(L=2); 12(L=3)$



运动分析

- ☐ 二维运动模型
- ☐ 二维运动 vs. 光流
- ☐ 运动估计中的一般方法
- ☐ 基于块的运动估计
- ☐ 可形变块匹配
- ☐ 多分辨率运动估计
- ☐ **相位相关法**
- ☐ 基于深度学习的运动分析

相位相关法



识别相位相关函数的峰值 (PCF)

$$\psi_1(X) = \psi_2(X + d)$$

$$\bar{\psi}_1(f) = \bar{\psi}_2(f) \cdot e^{j2\pi d^T f}$$

$$\tilde{\psi}(f) = \frac{\bar{\psi}_1(f) \cdot \bar{\psi}_2^*(f)}{|\bar{\psi}_2(f) \cdot \bar{\psi}_2^*(f)|} = e^{j2\pi d^T f}$$

$$PCF(X) = F^{-1}\{\tilde{\psi}(f)\} = \delta(X + d)$$

□ Note

- 减轻边界采样效应：空间域加权窗函数
- 广泛应用于图像配准
- 优点：对光照变化不敏感



运动分析



- 二维运动模型
- 二维运动 vs. 光流
- 运动估计中的一般方法
- 基于块的运动估计
- 可形变块匹配
- 多分辨率运动估计
- 相位相关法
- **基于深度学习的运动分析**

基于图像对的光流估计

□ FlowNet

- 第一个基于深度学习的光流网络
- 构建了仿真数据集FlyingChairs
- 类似于U-Net的网络结构

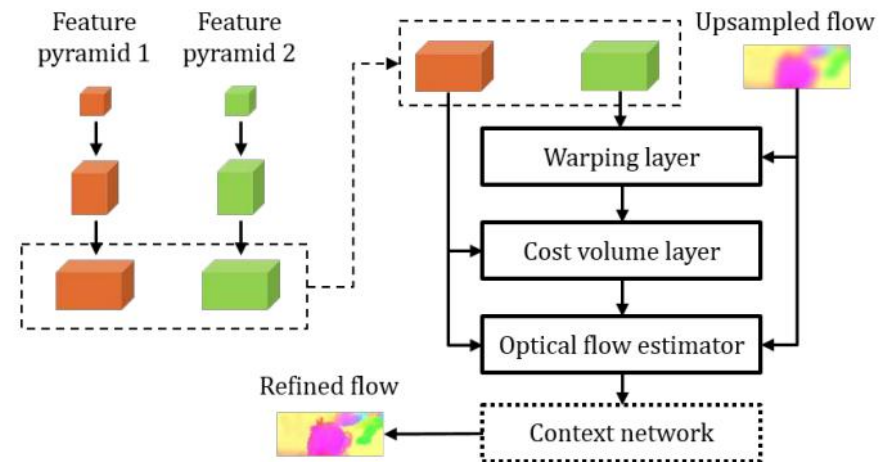
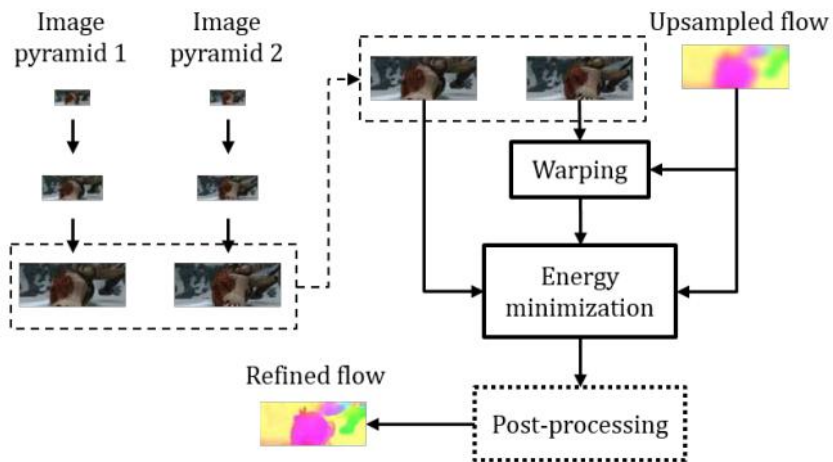
FlowNetSimple



基于图像对的光流估计

□ PWC-Net



- Feature pyramid
- Cost volume layer: store the matching costs for associating a pixel with its corresponding pixels at the next frame
- Context network: enlarge the receptive field size of each output unit at the desired pyramid level



基于图像对的光流估计

□ PWC-Net

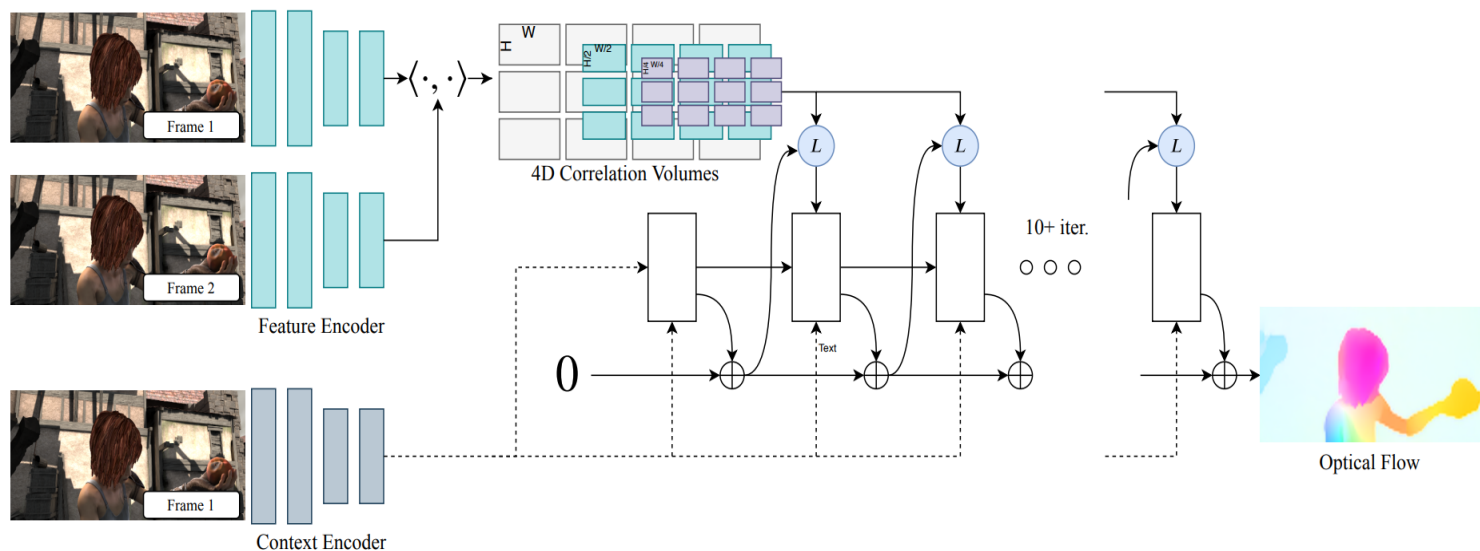
- PWC achieves the best performance at that time
- SpyNet has the lowest complexity



基于图像对的光流估计

□ RAFT


- 高分辨率下直接计算所有像素对的cost volume；inference极端多次迭代仅需计算一次
- 迭代网络是一个GRU，每次迭代共享参数，理论上可以无数次迭代；较为普适的一种渐进式思路
- 取得了当时最优的性能和泛化能力




基于图像对的光流估计

□ 基于Transformer的方法：GMFlow

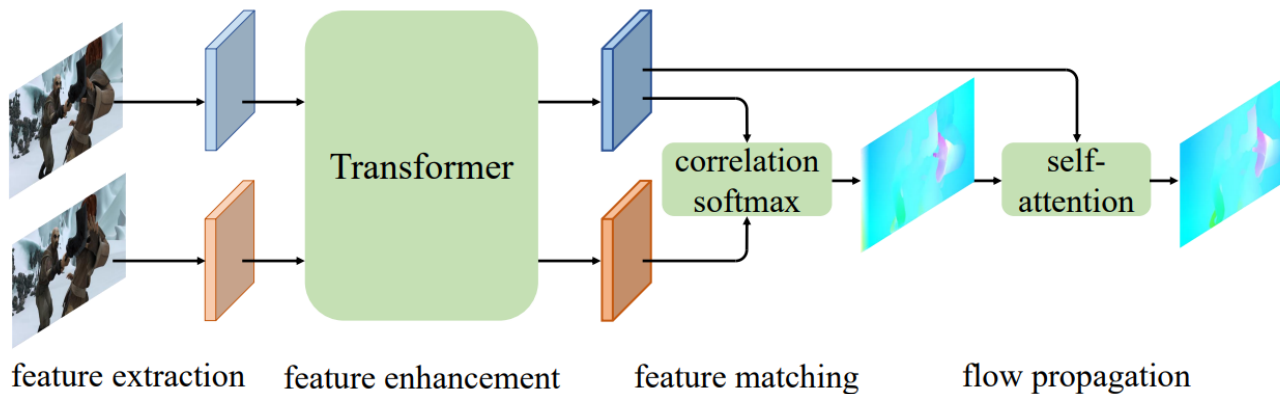
■ Global correlation matching



(a) previous flow estimation approach



(b) GMFlow



基于图像对的光流估计

□ 基于Transformer的方法：GMFlow

■ Best performance and efficiency than RAFT


Method	#refine.	Things (val, clean)				Sintel (train, clean)				Sintel (train, final)				Param (M)	Time (ms)
		EPE	s_{0-10}	s_{10-40}	s_{40+}	EPE	s_{0-10}	s_{10-40}	s_{40+}	EPE	s_{0-10}	s_{10-40}	s_{40+}		
RAFT [39]	0	14.28	1.47	3.62	40.48	4.04	0.77	4.30	26.66	5.45	0.99	6.30	35.19	5.3	25 (14)
	3	6.27	0.69	1.67	17.63	1.92	0.47	2.32	11.37	3.25	0.65	4.00	20.04		39 (21)
	7	4.66	0.55	1.38	12.87	1.61	0.39	1.90	9.61	2.80	0.53	3.30	17.76		58 (31)
	11	4.31	0.53	1.33	11.79	1.55	0.41	1.73	9.19	2.72	0.52	3.12	17.43		78 (41)
	23	4.22	0.53	1.32	11.52	1.47	0.36	1.63	9.00	2.69	0.52	3.05	17.28		133 (71)
	31	4.25	0.53	1.31	11.63	1.41	0.32	1.55	8.83	2.69	0.52	3.00	17.45		170 (91)
GMFlow	0	3.48	0.67	1.31	8.97	1.50	0.46	1.77	8.26	2.96	0.72	3.45	17.70	4.7	57 (26)
	1	2.80	0.53	1.01	7.31	1.08	0.30	1.25	6.26	2.48	0.51	2.81	15.67	4.7	151 (66)

Table 3. **RAFT’s iterative refinement framework vs. our GMFlow framework.** The models are trained on Chairs and Things training sets. We use RAFT’s officially released model for evaluation. The inference time is measured on a single V100 and A100 (in parentheses) GPU at Sintel resolution (436×1024). Our framework gains more speedup than RAFT ($2.29\times$ vs. $1.87\times$, *i.e.*, ours: $151 \rightarrow 66$, RAFT: $170 \rightarrow 91$) on the high-end A100 GPU since our method doesn’t require a large number of sequential computation.

基于多帧的光流估计

□ VideoFlow

- 同时对多帧估计双向光流



基于多帧的光流估计

□ VideoFlow

- Using three frames as an example
- Other structures similar to RAFT

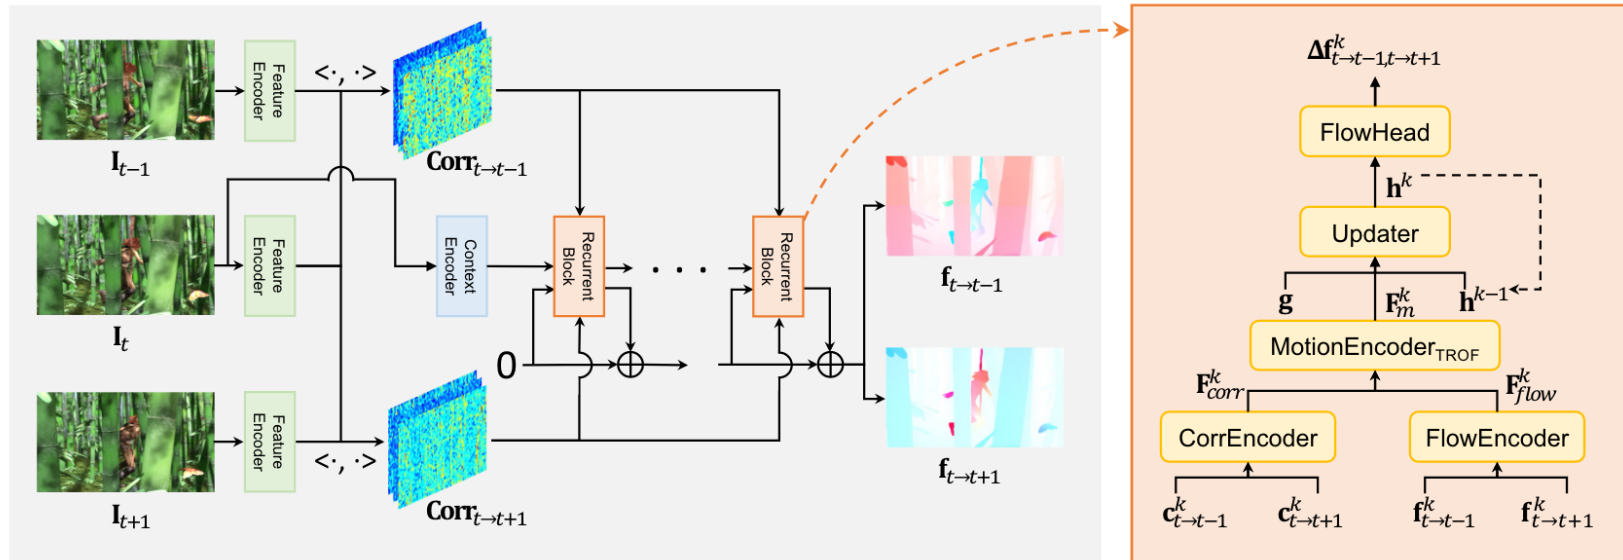
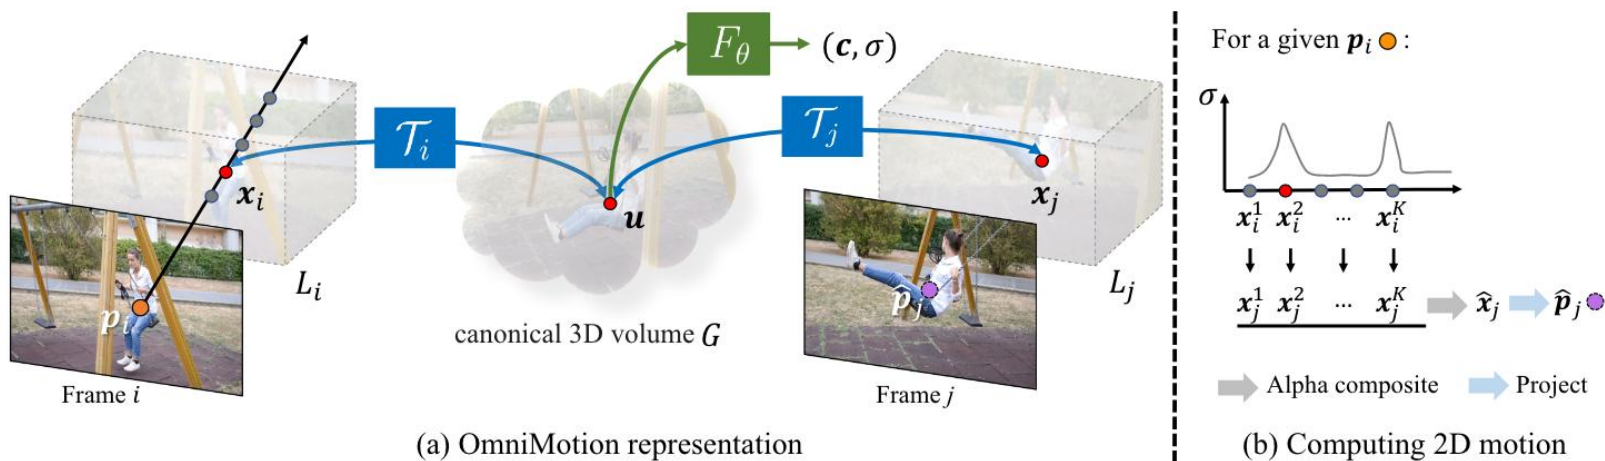


Figure 2. **Overview of VideoFlow in the three-frame setting.** Given a triplet of frames as input, VideoFlow jointly estimates bi-directional optical flows from the center frame to the adjacent previous and next frames. After building dual cost volumes, it recurrently fuses bi-directional flow features and correlation features to update flow predictions. The orange block on the right illustrates the recurrent flow refinement block.

基于三维表征的光流估计

□ OmniMotion

- 从2D回到3D
- 3D空间不存在遮挡问题



基于三维表征的光流估计

□ OmniMotion

- 从表征中提取的伪深度图，说明确实可以把深度估计得较为准确




Figure 4: Pseudo-depth maps extracted from our representation, where blue indicates closer objects and red indicates further.